

Técnicas cuantitativas

Enric Aguilar y Benito Zaragozaí

21-Mar-2021

Índice general

Antes de empezar	5
0.1 Prerrequisitos	5
0.2 Tipos de ficheros	6
0.3 Un ejemplo muy sencillo	6
0.4 Estructura básica de un documento Markdown	7
0.5 Ejercicio	8
1 Introducción	9
1.1 R como lenguaje de programación	10
1.2 Utilizando RStudio	11
1.3 Interpretación de valores	11
1.4 Variables	12
1.5 Tipos basicos	13
1.6 Estructuras de datos	16
1.7 Tidyverse	17
1.8 Ejercicios	19
2 Estadística descriptiva	21
2.1 Tendencia central	22
2.2 Dispersión	25
2.3 Correlación	26
2.4 Ejercicios	33
3 Estadística inferencial	35
3.1 Distribuciones de probabilidad	35
3.2 Introduccion a los test de hipótesis	40
3.3 Promotions activity	53
3.4 Understanding hypothesis tests	62
3.5 Conducting hypothesis tests	65
3.6 Interpreting hypothesis tests	75
3.7 Conclusions	78
4 El muestreo estadístico	83

4.1	Example one	83
4.2	Example two	83
5	Regresiones	85
6	Estadística multivariante	87

Antes de empezar

En este breve capítulo explicamos los aspectos básicos para que podáis reproducir los ejercicios y entregar las actividades utilizando R, Markdown y Rstudio. Aquí planteamos los conceptos básicos para preparar un documento que incluye explicaciones, código y los resultados de análisis R. Se trata de una estrategia de *programación literaria* que en los últimos años está siendo cada vez más utilizada en el análisis de datos (Knuth, 1984; Xie, 2015).

0.1 Prerrequisitos

Para seguir las explicaciones de este curso será necesario instalar primero R y RStudio con los paquetes `knitr` y `rmarkdown`. A continuación mostramos la configuración general del sistema R utilizado.

```
sessionInfo()
```

```
## R version 4.0.2 (2020-06-22)
## Platform: x86_64-pc-linux-gnu (64-bit)
## Running under: Ubuntu 20.04 LTS
##
## Matrix products: default
## BLAS/LAPACK: /usr/lib/x86_64-linux-gnu/openblas-pthread/libopenblas-r0.3.8.so
##
## locale:
##  [1] LC_CTYPE=C.UTF-8      LC_NUMERIC=C           LC_TIME=C.UTF-8
##  [4] LC_COLLATE=C.UTF-8    LC_MONETARY=C.UTF-8    LC_MESSAGES=C
##  [7] LC_PAPER=C.UTF-8      LC_NAME=C              LC_ADDRESS=C
## [10] LC_TELEPHONE=C        LC_MEASUREMENT=C.UTF-8 LC_IDENTIFICATION=C
##
## attached base packages:
## [1] stats      graphics  grDevices  utils      datasets  methods    base
##
## other attached packages:
##  [1] ggrepel_0.8.2      viridis_0.5.1      viridisLite_0.3.0
##  [4] scales_1.1.1       patchwork_1.0.1     ggplot2movies_0.0.1
```

```
## [7] nycflights13_1.0.1  moderndive_0.5.0  infer_0.5.3
## [10] kableExtra_1.2.1    corrplot_0.84      pander_0.6.3
## [13] DiagrammeR_1.0.6.1  forcats_0.5.0      stringr_1.4.0
## [16] dplyr_1.0.2         purrr_0.3.4        readr_1.4.0
## [19] tidyr_1.1.2         tibble_3.0.3       ggplot2_3.3.2
## [22] tidyverse_1.3.0
##
## loaded via a namespace (and not attached):
## [1] httr_1.4.2          jsonlite_1.7.1      modelr_0.1.8
## [4] assertthat_0.2.1    highr_0.8           blob_1.2.1
## [7] cellranger_1.1.0    yaml_2.2.1          pillar_1.4.6
## [10] backports_1.1.10    glue_1.4.2          digest_0.6.25
## [13] RColorBrewer_1.1-2  rvest_0.3.6         snakecase_0.11.0
## [16] colorspace_1.4-1    htmltools_0.5.0     pkgconfig_2.0.3
## [19] broom_0.7.1         haven_2.3.1         bookdown_0.20
## [22] webshot_0.5.2       generics_0.0.2      farver_2.0.3
## [25] ellipsis_0.3.1      withr_2.3.0         janitor_2.0.1
## [28] formula.tools_1.7.1 cli_2.0.2           magrittr_1.5
## [31] crayon_1.3.4        readxl_1.3.1        evaluate_0.14
## [34] fs_1.5.0            fansi_0.4.1         operator.tools_1.6.3
## [37] xml2_1.3.2          tools_4.0.2         hms_0.5.3
## [40] lifecycle_0.2.0     munsell_0.5.0       reprex_0.3.0
## [43] compiler_4.0.2      rlang_0.4.7         grid_4.0.2
## [46] rstudioapi_0.11     htmlwidgets_1.5.2   visNetwork_2.0.9
## [49] labeling_0.3        rmarkdown_2.4       gtable_0.3.0
## [52] DBI_1.1.0           R6_2.4.1            gridExtra_2.3
## [55] lubridate_1.7.9     knitr_1.30          utf8_1.1.4
## [58] stringi_1.5.3       Rcpp_1.0.5          vctrs_0.3.4
## [61] dbplyr_1.4.4        tidysselect_1.1.0   xfun_0.18
```

0.2 Tipos de ficheros

- Los archivos para producir documentos de RMarkdown tienen la extensión `.Rmd`.
- Los archivos deben abrirse con RStudio y se compilan haciendo clic en el botón `knitr`.
- El resultado es un documento en formato `.pdf`, `.html` o `.doc`.

0.3 Un ejemplo muy sencillo

Cread un fichero con el siguiente contenido

```
Hola, soy R Markdown
```

```
Aprende más sobre mi [aquí](http://rmarkdown.rstudio.com/).
```

al hacer clic en el botón `knitr` a HTML de Rstudio se crea un archivo `.html` con este contenido.

0.4 Estructura básica de un documento Markdown

Revisemos las partes más importantes del documento `Rmd`.

0.4.1 Cabecera

La cabecera está en la parte superior del documento dentro de estas dos líneas

```
---
title: "Write your title here"
author: "Write your name here"
date: "Write the date here"
output:
  pdf_document: default
  html_document: default
  word_document: default
---
```

En el encabezado del archivo debe escribir el título del documento, su nombre y la fecha. La declaración de salida se utiliza para la clase del documento final, `pdf`, `html` o `doc`. Para producir un PDF es necesario tener instalado un motor de LaTeX.

0.4.2 Insertar código R

A continuación, configuramos las opciones necesarias para imprimir el código R y la salida R en el documento final.

La primera línea es ocultar este fragmento de código en el documento final.

La segunda línea es para imprimir el código R y la salida R en el documento final.

0.4.3 Formatos de texto

El texto sin formato se escribe como en cualquier otro documento, como un documento de Word. Debe tener cuidado con las letras en cursiva o negrita y algunos caracteres especiales. Por ejemplo

- **Negrita**: escriba el texto entre `**Negrita**` o `__Negrita__`
- *Cursiva*: escriba su texto entre `*cursiva*` o `_Italica_`
- Encabezados de sección

```
# Título 1
```

```
## Título 2
### Título 3
```

Cuantos más símbolos `#` escriba antes de su texto, menor será el tamaño de su título

Puede encontrar más información sobre cómo escribir en el siguiente archivo.

0.4.4 Generando el documento

Para compilar el archivo `.Rmd` y obtener su documento final, simplemente haga clic en el botón Knit y seleccione Knit a PDF para producir un archivo `.pdf`.

0.5 Ejercicio

- Utilizando Rstudio, crea tu primer documento con Rmarkdown. El documento debe mostrar los metadatos básicos (título, autor y fecha), un título de primer nivel (por ejemplo, ‘Información de la sesión’) y un recuadro con la información básica de vuestra sesión de R.

Capítulo 1

Introducción

Para cuando llega el momento de analizar los datos, la mayor parte del trabajo ya está hecho. Antes de tener un conjunto de datos se ha tenido que definir el problema de investigación, desarrollar e implementar un plan de muestreo, decidir las escalas de medidas y desarrollar un diseño de investigación. Si se ha hecho bien este trabajo, el análisis de los datos puede ser bastante sencillo.

En la mayoría de las investigaciones de ciencias sociales, el análisis de datos implica tres pasos principales, realizados aproximadamente en este orden:

1. Limpieza y organización de los datos para su análisis (preparación de datos)
2. Describir los datos (estadística descriptiva)
3. Prueba de hipótesis y modelos (estadística inferencial)

La **preparación de datos** implica verificar o registrar los datos, comprobar su exactitud, cargar los datos en el software de análisis, transformar los datos y crear una base de datos adecuada para el análisis que se vaya a realizar.

Las **estadísticas descriptivas** se utilizan para describir las características básicas de los datos en un estudio. Proporcionan resúmenes sencillos sobre la muestra y las medidas. Junto con el análisis gráfico simple, forman la base de prácticamente todos los análisis cuantitativos de datos. Las estadísticas descriptivas simplemente se *describen los datos*.

La **estadística inferencial** investiga preguntas, modelos e hipótesis. En muchos casos, las conclusiones de la estadística inferencial se extienden más allá de los datos inmediatos por sí solos. Por ejemplo, usamos estadísticas inferenciales para tratar de inferir de los datos de la muestra lo que piensa la población total. También utilizamos estadística inferencial para hacer juicios sobre la probabilidad de que una diferencia observada entre grupos sea confiable o si podría haber ocurrido por casualidad en este estudio. Por lo tanto, usamos estadísticas inferenciales para *inferir lo que sucede más allá de nuestros datos*.

En la mayoría de los estudios de investigación, la sección de análisis sigue estas tres fases de análisis. Las descripciones de cómo se prepararon los datos tienden a ser breves y a centrarse solo en los aspectos más exclusivos de su estudio, como las transformaciones de datos específicas que se realizan. Las estadísticas descriptivas que observa en realidad pueden ser voluminosas. En la mayoría de los estudios, las estadísticas descriptivas se seleccionan cuidadosamente y se organizan en tablas de resumen y gráficos que solo muestran la información más relevante o importante. Por lo general, el investigador vincula cada uno de los análisis inferenciales con preguntas o hipótesis de investigación específicas que se plantearon en la introducción, o toma nota de los modelos que se probaron y que surgieron como parte del análisis. En la mayoría de los informes de análisis, es especialmente importante *“no dejar que los árboles nos impidan ver el bosque”*. Si se presentan demasiados detalles sobre el análisis, es posible que se pierda de vista el problema de la realidad que estamos estudiando.

Todos estos pasos del análisis se pueden realizar habitualmente en todos los paquetes estadísticos. En este curso nos centraremos en el uso de R, por lo que a continuación haremos una breve introducción.

1.1 R como lenguaje de programación

R fue creado en 1992 por Ross Ihaka y Robert Gentleman en la Universidad de Auckland, Nueva Zelanda. R es una implementación gratuita de código abierto del lenguaje de programación estadística **S** creado inicialmente en Bell Labs. En esencia, R es un lenguaje de programación funcional (sus principales funcionalidades giran en torno a la definición y ejecución de funciones). Sin embargo, ahora es compatible, y se usa comúnmente como un lenguaje de programación imperativo (enfocado en instrucciones sobre variables y estructuras de control de programación) y orientado a objetos (que involucra estructuras de objetos complejas).

En términos simples, hoy en día, la programación en R se enfoca principalmente en diseñar una serie de instrucciones para ejecutar una tarea, más comúnmente, cargar y analizar un conjunto de datos (Wickham and Grolemund, 2017).

Como tal, R se puede usar para programar creando secuencias de **instrucciones** que involucren **variables**, que son entidades con nombre que pueden almacenar valores. Ese será el tema principal de esta sesión práctica. Las instrucciones pueden incluir estructuras de flujo de control, como puntos de decisión (*if/else*) y bucles, que serán el tema de la próxima sesión práctica. Las instrucciones también se pueden agrupar en **funciones**, que también veremos en la próxima sesión práctica.

R es **interpretado**, no compilado. Lo que significa que un intérprete de R (si está utilizando R Studio, el intérprete de R simplemente está oculto en el backend y R Studio es el frontend que le permite interactuar con el intérprete) recibe una instrucción que escribe en R, la interpreta y la ejecuta .

Otros lenguajes de programación requieren que su código sea compilado en un ejecutable para ser ejecutado en un ordenador.

1.2 Utilizando RStudio

La interfaz de RStudio se divide en dos secciones principales. En el lado izquierdo, encontrará la *Consola*, así como el editor de secuencias de comandos R, cuando se está editando una secuencia de comandos. La *Consola* es una ventana de entrada/salida en el intérprete de R, donde se pueden escribir instrucciones y se muestra la salida calculada.

Por ejemplo, si escribís en la *Consola*

```
1 + 1
```

el intérprete de R entiende eso como una instrucción para sumar uno más uno, y produce el resultado (dado que los materiales para este módulo se crean en RMarkdown, la salida del cálculo siempre está precedida por ‘##’).

```
## [1] 2
```

Fíjate cómo el valor de salida 2 está precedido por [1], lo que indica que la salida está constituida por un solo elemento. Si la salida está constituida por más de un elemento, como la lista de números a continuación, cada fila de la salida está precedida por el índice del primer elemento de la salida.

```
## [1] 1 4 9 16 25 36 49 64 81 100 121 144 169 196 225 256 289 324 361
## [20] 400
```

En el lado derecho, encontrarás dos grupos de paneles. En la parte superior derecha, el elemento principal es el panel *Entorno*, que es una representación del estado actual de la memoria del intérprete y, como tal, muestra todas las variables, conjuntos de datos y funciones almacenados. En la parte inferior derecha, encontrarás el panel *Archivos*, que muestra el sistema de archivos (archivos y carpetas del ordenador), así como el panel *Ayuda*, que le muestra las páginas de ayuda cuando sea necesario. Discutiremos los otros paneles más adelante.

1.3 Interpretación de valores

Cuando se escribe un valor en la *Consola*, el intérprete simplemente devuelve el mismo valor. En los ejemplos siguientes, 2 es un valor numérico simple, mientras que "Valor de cadena" es un valor textual, que en R se conoce como un valor de *carácter* y en programación también se conoce comúnmente como una *cadena* (abreviatura de *una cadena de caracteres*).

Ejemplo numérico

2

```
## [1] 2
```

Ejemplo de cadena

```
"String value"
```

```
## [1] "String value"
```

Tened en cuenta que los valores de los caracteres deben comenzar y terminar con comillas simples o dobles ('o"), que no forman parte de la información en sí. La Guía de estilo de Tidyverse sugiere usar siempre comillas dobles ("), así que serán las que usaremos en este curso.

Todo lo que sigue a un símbolo # se considera un *comentario* y el intérprete lo ignora. Cada lenguaje de programación puede usar sus propios símbolos para identificar los comentarios. Por ejemplo cabe destacar la diferencia entre # en Markdown que identifica un título de primer nivel, mientras que los comentarios en un fichero de Rmarkdown se identifican entre < y >.

```
# Este comentario es ignorado por R. Solo sirve para documentar el código.
```

Como se ha mencionado anteriormente, el intérprete también comprende operaciones aritméticas simples sobre valores numéricos.

```
1 + 1
```

```
## [1] 2
```

Además, también hay una gran cantidad de funciones predefinidas, por ejemplo, raíz cuadrada: `sqrt`.

```
sqrt(2)
```

```
## [1] 1.414214
```

Las funciones se recopilan y almacenan en *bibliotecas* (a veces denominadas *paquetes*), que contienen funciones relacionadas. Las bibliotecas pueden variar desde la biblioteca `base`, que incluye la función `sqrt` anterior, hasta la biblioteca `rgdal`, que funciona como un puente hacia las funciones de la GDAL (Biblioteca de abstracción de datos geoespaciales), que es una importante librería en el mundo de los Sistemas de Información Geográfica. Por lo tanto, es mediante la creación de librerías que podemos extender las capacidades de R.

1.4 Variables

Una variable se puede definir usando un **identificador** (por ejemplo, `una_variable`) a la izquierda de un **operador de asignación** `<-`, seguido del *objeto* que se vinculará al identificador, como un **valor** (por ejemplo, 1) que se

asignará a la derecha. Una vez realizada la asignación, el valor de la variable se puede probar/invocar simplemente especificando el **identificador**.

```
una_variable <- 1
una_variable
```

```
## [1] 1
```

Si escribes `una_variable <- 1` en la *Consola* de RStudio, aparece un nuevo elemento en el panel *Environment* (derecha-arriba), que representa la nueva variable en la memoria. La parte izquierda de la entrada contiene el identificador `una_variable`, y la parte derecha contiene el valor asignado a la variable `una_variable`, es decir, 1.

No es necesario aportar un valor directamente. La parte derecha de la tarea puede ser una **llamada a una función**. En ese caso, la función se **ejecuta** en la entrada proporcionada y **el resultado se asigna a la variable**.

```
una_variable <- sqrt(4)
una_variable
```

```
## [1] 2
```

Observa cómo, al escribir `una_variable <- sqrt(4)` en la *Consola* de RStudio, el elemento en el panel *Environment* cambia para reflejar el nuevo valor asignado a `una_variable`, que ahora es el resultado de `sqrt(4)`, es decir 2.

En el siguiente ejemplo, se crea otra variable llamada `otra_variable` y se suma a `una_variable`, guardando el resultado en `suma_de_dos_variables`. La raíz cuadrada de esa suma se almacena en la variable `raiz_cuadrada_de_suma`.

```
otra_variable <- 4
otra_variable
```

```
## [1] 4
```

```
suma_de_dos_variables <- una_variable + otra_variable
```

```
raiz_cuadrada_de_suma <- sqrt(suma_de_dos_variables)
raiz_cuadrada_de_suma
```

```
## [1] 2.44949
```

1.5 Tipos basicos

1.5.1 Números

El tipo *numeric* representa números en general (tanto enteros como reales), pero R es capaz de distinguirlos utilizando funciones.

```
un_numero <- 1.41
is.numeric(un_numero)

## [1] TRUE
is.integer(un_numero)

## [1] FALSE
is.double(un_numero) # i.e., es real

## [1] TRUE
```

Operadores numéricos básicos.

Operador	Significado	Ejemplo	Resultado
+	Suma	5+2	7
-	Resta	5-2	3
*	Multiplicación	5*2	10
/	División	5/2	2.5
%%	Div. de enteros	5%%2	2
%%	Módulo	5%%2	1
^	Potencia	5^2	25

Algunas funciones predefinidas en R son:

```
abs(-2) # Valor absoluto

## [1] 2
ceiling(3.475) # Redondeo al alza

## [1] 4
floor(3.475) # Redondeo a la baja

## [1] 3
trunc(5.99) # Truncar

## [1] 5
log10(100) # Logaritmo en base 10

## [1] 2
log(exp(2)) # Logaritmo natural y exponencial

## [1] 2
```

Como en cualquier otro entorno, podéis utilizar paréntesis simples para

especificar el orden de ejecución. Si no se especifica, el orden predeterminado es: potencia, multiplicación y división, suma y resta al final.

```
un_numero <- 1
(un_numero + 2) * 3
```

```
## [1] 9
```

```
un_numero + (2 * 3)
```

```
## [1] 7
```

```
un_numero + 2 * 3
```

```
## [1] 7
```

R devuelve el resultado NaN (*Not a number*) cuando el resultado de una operación no es un número.

```
0/0
```

```
## [1] NaN
```

```
is.nan(0/0)
```

```
## [1] TRUE
```

No hay que confundir NaN con NA (*No Available*), que sirve para identificar datos faltantes.

1.5.2 Lógicos o booleanos

El tipo *lógico* codifica dos valores dicotómicos: Verdadero y Falso.

```
valor_logico <- TRUE
is.logical(valor_logico)
```

```
## [1] TRUE
```

```
isTRUE(valor_logico)
```

```
## [1] TRUE
```

```
as.logical(0) # se pueden convertir 1/0 a TRUE/FALSE
```

```
## [1] FALSE
```

Operadores lógicos básicos

Operador	Significado	Ejemplo	Resultado
==	Igual	5==2	FALSE
!=	No igual	5!=2	TRUE
>	Mayor que	5>2	TRUE

Operador	Significado	Ejemplo	Resultado
<	Menor que	5<2	FALSE
>=	Mayor o igual	5>=2	TRUE
<=	Menor o igual	5<=2	FALSE
!	No	!TRUE	FALSE
&	Y	TRUE & FALSE	FALSE
	O	TRUE FALSE	TRUE

1.5.3 Cadenas de caracteres

El tipo *character* representa objetos de texto, incluidos caracteres individuales y cadenas de caracteres (es decir, objetos de texto de más de un carácter, comúnmente denominados simplemente *cadenas* o *strings* en informática).

```
una_cadena <- "¡Hola!"
is.character(una_cadena)

## [1] TRUE
is.numeric(una_cadena)

## [1] FALSE
as.character(2) # Conversión de número a cadena (en inglés, hacer un 'cast')

## [1] "2"
as.numeric("2")

## [1] 2
as.numeric("¡Hasta luego!")

## Warning: NAs introduced by coercion
## [1] NA
```

1.6 Estructuras de datos

Estos tipos de datos más básicos se gestionan habitualmente dentro de estructuras de datos más complejas. R tiene muchas otras estructuras de datos pero las más básicas comprenden:

- Vectores
- Listas
- Matrices
- *data frames* (se usa el término en inglés por comodidad).
- Factores

1.6.1 Vectores

1.6.2 Listas

1.6.3 Matrices

1.6.4 Data frames

1.6.5 Factores

1.7 Tidyverse

Como se ha mencionado anteriormente, las librerías o *paquetes* son colecciones de funciones y/o conjuntos de datos. Las librerías se pueden instalar en R usando la función `install.packages()` o usando el menú **Herramientas > Instalar Librerías** ...en RStudio. Algunas librerías de R están relacionadas entre sí o forman parte de flujos de trabajo mayores. A día de hoy la meta-librería Tidyverse contiene algunas de las librerías más utilizadas en el análisis de datos (Wickham et al., 2019). Solo por mencionar algunas:

- `ggplot2` para crear gráficos.
- `dplyr` para manipular datos (filtrar, seleccionar, agregar, sumarizar, etc).
- `tidyr` para organizar los datos de un modo que las otras librerías del **Tidyverse** puedan trabajar mejor.
- `readr` para importar tablas de datos a partir de formatos habituales (csv, tsv, o fwf). Permite minimizar la introducción de errores en la importación.
- `purrr` se utiliza para facilitar la automatización de tareas en R, mientras se escribe menos código.
- `stringr` facilita la manipulación de cadenas de texto (unir, separar, filtrar palabras en un documento, etc).
- `forcats` para trabajar con factores.
- `tibble`...

Se puede cargar una librería usando la función `library()`, como se muestra a continuación (tened en cuenta que el nombre de la biblioteca no está entrecomillado). Una vez que una librería está instalada en un ordenador, no es necesario que la instale nuevamente, pero cada secuencia de comandos o *script* debe cargar todas las librerías que utiliza. Una vez que se carga una librería, se pueden utilizar todas sus funciones.

```
library(tidyverse)
```

1.7.1 stringr

El siguiente código presenta un mínimo ejemplo del uso de las funciones de la librería `stringr`.

```
str_length("Tarragona")
```

```
## [1] 9
str_detect("Tarragona", "a")

## [1] TRUE
str_replace_all("Tarragona", "r", "R")

## [1] "TaRRagona"
```

1.7.2 El operador pipe

El operador `pipe` (tubería) es útil para reducir el número de asignaciones en operaciones más complejas. Un *pipe* (`%>%`) toma el resultado de una función y lo pasa a la siguiente función como **primer argumento**, de este modo ya no hace falta repetir el resultado de la primera función en el código.

El siguiente código muestra un ejemplo sencillo. El número 2 se toma como entrada para el primer `pipe` que lo pasa como primer argumento a la función `sqrt`. El valor de salida 1.4142136 se toma como entrada para el segundo `pipe`, que lo pasa como primer argumento a la función `trunc`. Finalmente se devuelve la salida final “1”.

```
2 %>%
  sqrt() %>%
  trunc()

## [1] 1
sqrt(2) %>%
  round(digits = 2)
```

El primer paso de una secuencia de *pipes* puede ser un valor, una variable o una función que incluya argumentos. El siguiente código muestra una serie de ejemplos de diferentes formas de lograr el mismo resultado. Los ejemplos usan la función `round`, que también permite un segundo argumento `digits = 2`. Tened en cuenta que, cuando se utiliza el operador `%>%`, solo se proporciona el segundo argumento nominalmente a la función `round`, es decir, `round(digits = 2)`

```
# R básico, sin utilizar '%>%', pero en varios pasos
variable_temporal_a <- 2
variable_temporal_b <- sqrt(variable_temporal_a)
round(variable_temporal_b, digits = 2)

# R básico, sin utilizar '%>%', pero sin asignaciones
round(sqrt(2), digits = 2)

# Pipe a partir de un valor
2 %>%
  sqrt() %>%
```

```

round(digits = 2)

# Pipe a partir de una variable
el_numero_dos <- 2
el_numero_dos %>%
  sqrt() %>%
  round(digits = 2)

# Pipe empezando por una función
sqrt(2) %>%
  round(digits = 2)

```




Figura 1.1: Ejecución del código sin o con `%>%`. Sin *pipes* los resultados intermedios tienen que guardarse en una variable en memoria.

Una operación compleja creada mediante el uso de `%>%` se puede usar en el lado derecho de una asignación `<-`, de modo que se guarda resultado de toda la operación de la derecha.

```

raiz_cuadrada_de_dos <- 2 %>%
  sqrt() %>%
  round(digits = 2)

```

1.8 Ejercicios

Crea un *script* para responder a cada pregunta. En las preguntas de la 4 a la 8 es posible que tengas que consultar la referencia de la librería **stringr** (stringr.tidyverse.org/reference) o a otras funciones de **R base**.

1. Escribe un fragmento de código utilizando el operador `%>%` que haga lo siguiente:
 - tomar como entrada el número 1632
 - calcular el logaritmo en base 10
 - redondear el número a la baja
 - truncar la parte entera y
 - verificar si se trata de un número entero.
2. Escribe un fragmento de código utilizando el operador `%>%` que haga lo siguiente:
 - tomar como entrada el número 1632

- calcular la raíz cuadrada,
 - redondear al alza y quedarse con la parte entera, y
 - verificar que se trata de un entero.
3. Escribe un fragmento de código utilizando el operador `%>%` que haga lo siguiente:
 - tomar como entrada la cadena `1632`
 - convertirla a número
 - comprobar si el resultado es o no un número.
 4. Escribe un fragmento de código utilizando el operador `%>%` que haga lo siguiente:
 - tomar como entrada la cadena `"-16.32"`
 - transformarla en un número
 - calcular el valor absoluto y truncarlo
 - comprobar si el resultado es o no un número.
 5. Escribe un fragmento de código utilizando el operador `%>%` y la librería `and the stringr` que haga lo siguiente:
 - tomar la cadena `"Siempre r que r"` como entrada
 - transformar la cadena a mayúsculas.
 6. Escribe un fragmento de código utilizando el operador `%>%` y la librería `and the stringr` que haga lo siguiente:
 - tomar la cadena `"Siempre r que r"` como entrada
 - truncarla para dejar solamente `'Siempre R'`.

Capítulo 2

Estadística descriptiva

La estadística descriptiva es una rama de la estadística cuyo objetivo es resumir, describir y presentar una serie de valores o un conjunto de datos. Estas estadísticas pueden ser realmente útiles al analizar largas series de datos en las que resulte difícil reconocer algún patrón. En éste capítulo utilizaremos una muestra de datos sobre salarios (en euros) de una *población* de 100 trabajadores:

2186, 1218, 1682, 1816, 1702, 1447, 2256, 1453, 2509, 1469, 2152, 2643, 805.6, 1361, 1433, 1818, 1358, 171.8, 279.8, 2160, 1347, 609.3, 1414, 2107, 2448, 1285, 1371, 618.4, 1730, 1180, 1728, 1852, 2018, 1196, 1752, 641.5, 1108, 1074, 292.9, 1518, 1603, 1320, 1879, 1137, 815.9, 1716, 1094, 2222, 1284, 1828, 1661, 1108, 2288, 1821, 1545, 1638, 1840, 1545, 3.5, 1642, 1316, 1593, 1791, 2200, 1136, 2151, 1668, 2019, 1960, 1860, 978.4, 1455, 1812, 1023, 1229, 1790, 1884, 1732, 1057, 950.1, 2256, 1629, 1544, 1440, 902.8, 1806, 1391, 1409, 1967, 1911, 2196, 1262, 1825, 2196, 944.6, 1070, 934.1, 770.4, 1540 and 1827

De un primer vistazo es difícil (por no decir imposible) que podamos comprender los datos y tener una visión clara de los salarios de este grupo de personas. Las estadísticas descriptivas permiten resumir y así tener una mejor visión general de los datos. Por supuesto, al resumir los datos a través de una o varias medidas, inevitablemente se perderá parte de la información. Sin embargo, en muchos casos es mejor perder algo de información pero, a cambio, obtener una visión general. Podríamos decir que se trata de *ganar perspectiva*.

La estadística descriptiva es a menudo el primer paso y una parte importante en cualquier análisis estadístico. Permite comprobar la calidad de los datos detectando posibles valores atípicos (*outliers*), es decir, datos que parecen ser significativamente distintos del resto. También se puede utilizar estadística descriptiva para detectar errores de recopilación o codificación, determinar si están bien presentados, entre otras posibles aplicaciones.

Podemos distinguir dos tipos básicos de estadísticos para describir un conjunto

de datos: de centralidad y de dispersión. Habitualmente, ambos tipos de medidas se utilizan juntos para resumir los datos de la forma más concisa.

2.1 Tendencia central

Las medidas de tendencia central permiten ver “dónde” se ubican los datos, alrededor de qué valores. En otras palabras, las medidas de ubicación permiten comprender cuál es la tendencia central o la “posición” de los datos en su conjunto. Entre las estadísticas más habituales de este tipo podemos distinguir:

- Mínimo y máximo
- Media
- Mediana
- Primer cuartil
- Tercer cuartil
- Moda

2.1.1 Mínimo y máximo

Mínimo (*min*) y máximo (*max*) son simplemente los valores más bajo y más alto de la muestra. Dada una muestra de 6 de estos salarios:

2186, 1218, 1682, 1816, 1702 and 1447

El mínimo es 1217.7 euros y el máximo es 2185.5 euros. Estas dos estadísticas básicas dan una idea clara sobre el los extremos de la muestra y su cálculo con R es bastante sencillo:

```
min(salarios_sel)
```

```
## [1] 1217.7
```

```
max(salarios_sel)
```

```
## [1] 2185.5
```

2.1.2 Media

La media o promedio, es probablemente la estadística más habitual. Da una idea de cuál es el valor medio, es decir, el valor central de los datos o, en otras palabras, su centro de gravedad. La media se encuentra sumando todos los valores y dividiendo esta suma por el número de observaciones (n):

$$Media = \bar{x} = \frac{\text{suma de todos los valores}}{\text{número de valores}} = \frac{1}{n} \sum_{i=1}^n x_i$$

Dada nuestra muestra de 6 salarios presentada anteriormente, la media es:

$$\bar{x} = \frac{2186 + 1218 + 1682 + 1816 + 1702 + 1447}{6} = 1675,033$$

En conclusión, el tamaño medio de la nuestra muestra es 1675.03 euros (redondeado a 2 decimales). El cálculo con R también resulta bastante sencillo:

```
mean(salarios_sel)
```

```
## [1] 1675.033
```

2.1.3 Mediana

La mediana es otra medida de centralidad. La interpretación de la mediana es que hay tantas observaciones por debajo como por encima de la mediana. En otras palabras, el 50% de las observaciones se encuentran por debajo de la mediana y el 50% de las observaciones están por encima de la mediana.

La forma más fácil de calcular la mediana es primero ordenar los datos de menor a mayor (es decir, en orden ascendente) y luego tomar el punto medio como la mediana. A partir de los valores ordenados, para un número impar de observaciones, el punto medio es fácil de encontrar: es el valor con tantas observaciones abajo como arriba. Aún a partir de los valores ordenados, para un número par de observaciones, el punto medio está exactamente entre los dos valores medios. Formalmente, después de ordenar, la mediana es:

- si n (número de observaciones) es impar:

$$mediana(x) = x_{\frac{n+1}{2}}$$

- si n es par:

$$mediana(x) = \frac{1}{2}(x_{\frac{n}{2}} + x_{\frac{n}{2}+1})$$

donde el subíndice de x denota la numeración de los datos ordenados. El cálculo en R es de nuevo bastante sencillo:

```
median(salarios_sel)
```

```
## [1] 1691.85
```

2.1.4 Primer y tercer cuartil

El primer y tercer cuartil son similares a la mediana en el sentido de que también dividen las observaciones en dos partes, solo que estas partes no son iguales. Recordad que la mediana divide los datos en dos partes iguales (con el 50% de las observaciones por debajo y el 50% por encima de la mediana). El primer cuartil divide las observaciones de modo que haya un 25% de las observaciones *debajo de* este punto y un 75% **por encima** del primer cuartil. El tercer cuartil se calcula del mismo modo pero representa el valor con el 75% de las observaciones

por debajo y el 25% de las observaciones por encima. Existen varios métodos para calcular el primer y tercer cuartil, pero por ejemplo se puede calcular siguiendo los siguientes pasos:

1. Ordenar los datos en orden ascendente
2. Calcular $0.25 \cdot n$ y $0.75 \cdot n$ (es decir, 0.25 y 0.75 veces el número de observaciones)
3. Redondear estos dos números al siguiente número entero `ceil`

Los pasos son los mismos para un número par e impar de observaciones. A continuación se muestra un ejemplo para el cálculo de estos valores sobre los salarios de nueve trabajadores:

```
quantile(salarios_sel)
```

```
##          0%          25%          50%          75%         100%
## 1217.700 1505.575 1691.850 1787.825 2185.500
```

Dado que obtenemos un vector de resultados, podemos seleccionar por posición para obtener el que necesitamos en cada caso.

2.1.5 Moda

La moda de una serie es el valor que aparece con mayor frecuencia. En otras palabras, es el valor que tiene el mayor número de ocurrencias. Dados los siguientes salarios:

1700, 1680, 1710, 1700, 1820, 1650, 1700, 1890 and 1670

La moda es 1700 porque es el valor más común con 3 apariciones. Todos los demás valores aparecen solo una vez. En conclusión, la mayoría de los trabajadores de esta muestra perciben exactamente 1700 euros al mes.

Hay que tener en cuenta que es posible que una serie no tenga moda (p. Ej., 4, 7, 2 and 10) o más de una moda (p. Ej., 4, 2, 2, 8, 11 and 11). Los datos con dos modas a menudo se denominan bimodales y los datos con más de dos modos a menudo se denominan multimodales, a diferencia de las series con una moda, que se denominan unimodales.

A diferencia de las anteriores estadísticas (mínimo, máximo, media, mediana, primer y tercer cuartil) que solo se pueden calcular para variables cuantitativas, **la moda se puede calcular para variables cuantitativas y cualitativas**. Atendiendo al tipo de empleo que desarrollan los 9 trabajadores presentados anteriormente:

ingeniero, ingeniero, ingeniero, ingeniero, asistente, asistente, asistente, ingeniero and camarero

La moda es “ingeniero”, por lo que la mayoría de los trabajadores de esta muestra son de uso ingenieros.

2.2 Dispersión

2.2.1 Rango

El rango es la diferencia entre el máximo y el mínimo:

$$rango = max - min$$

Dada nuestra muestra de salarios:

2186, 1218, 1682, 1816, 1702 and 1447

El rango es $2185.5 - 1217.7 = 967.8$ euros. El rango es muy sencillo de calcular y en algunos casos puede dar una buena idea de lo que podemos esperar de un conjunto de datos. En R se puede utilizar la función `range`

```
range(salarios_sel)
```

```
## [1] 1217.7 2185.5
```

No obstante, esta métrica no da ninguna información de la distribución interna del resto de medidas.

2.2.2 Desviación estándar

La desviación estándar es la medida de dispersión más común en estadística. Si tenemos que presentar una estadística que resuma la distribución de los datos, suele ser la desviación estándar. Como sugiere su nombre, la desviación estándar indica cuál es la desviación *normal* de los datos. De hecho, calcula la desviación promedio de la **media**. Cuanto mayor sea la desviación estándar, más dispersos estarán los datos. Por el contrario, cuanto menor es la desviación estándar, más se centran los datos alrededor de la media.

Existen dos fórmulas para calcular la desviación estándar en función de si nos enfrentamos a una muestra o a una población. Una población incluye a todos los miembros de un grupo específico, mientras que una muestra contiene algunas observaciones extraídas de la población, es decir, una parte o un subconjunto de la población. Por ejemplo, la población puede ser “**todas** personas que viven en España” y la muestra puede ser “**algunas** personas que viven en España”.

La desviación estándar para una población, a partir de ahora σ , es:

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

Como se puede ver en la fórmula, la desviación estándar es en realidad la desviación promedio de los datos de su media μ . Hay calcular primero el cuadrado de la diferencia entre las observaciones y la media para evitar que las diferencias negativas se compensen con diferencias positivas.

Por ejemplo, imagine una población de solo 3 trabajadores:

770.4, 1540 and 1827

La media es 1379 (redondeado a 1 decimal). La desviación estándar es entonces:

$$\sigma = \sqrt{\frac{1}{3}[(770.4 - 1379)^2 + (1540 - 1379)^2 + (1827 - 1379)^2]}$$

$$\sigma = 546,2$$

Por lo tanto, la desviación estándar para los salarios de estos trabajadores es de 546,2 euros. Esto significa que los salarios de los trabajadores de esta población se desvían de la media en 546,2 euros.

...

2.2.3 Varianza

2.2.4 Coeficiente de variación

2.3 Correlación

Las correlaciones entre variables juegan un papel importante en un **análisis descriptivo**. Una correlación mide la **relación entre dos variables**, es decir, cómo están vinculadas entre sí. En este sentido, una correlación permite saber si dos variables evolucionan en la misma dirección, en sentido contrario y si son independientes.

En este capítulo, se muestra cómo calcular **coeficientes de correlación**, cómo realizar **pruebas de correlación** y cómo **visualizar** correlaciones entre variables usando R.

La correlación generalmente se calcula en dos variables *cuantitativas*, pero también se puede calcular en dos variables *cualitativas ordinales* (ver prueba de independencia de chi-cuadrado).

2.3.1 Datos

Usaremos el conjunto de datos `mtcars`. Este conjunto de datos viene cargado por defecto en R, de modo que se utiliza en numerosas demostraciones.

```
# mostrar las primeras cinco filas
head(mtcars, 5)
```

##		mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
##	Mazda RX4	21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
##	Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
##	Datsun 710	22.8	4	108	93	3.85	2.320	18.61	1	1	4	1

```
## Hornet 4 Drive      21.4    6  258 110 3.08 3.215 19.44  1  0    3    1
## Hornet Sportabout 18.7    8  360 175 3.15 3.440 17.02  0  0    3    2
```

Las variables `vs` y `am` son variables categóricas, por lo que se eliminan para este artículo:

```
# Eliminar las variables vs y am
library(tidyverse)
dat <- mtcars %>%
select(-vs, -am)

# mostrar las primeras cinco filas
head(dat, 5)
```

```
##           mpg cyl disp  hp drat   wt  qsec gear carb
## Mazda RX4      21.0   6  160 110 3.90 2.620 16.46   4    4
## Mazda RX4 Wag  21.0   6  160 110 3.90 2.875 17.02   4    4
## Datsun 710     22.8   4  108  93 3.85 2.320 18.61   4    1
## Hornet 4 Drive  21.4   6  258 110 3.08 3.215 19.44   3    1
## Hornet Sportabout 18.7   8  360 175 3.15 3.440 17.02   3    2
```

2.3.2 Coeficiente de correlación

La correlación entre 2 variables se calcula con la función `cor()`. Supón que queremos calcular la correlación entre caballos de potencia (`hp`) y millas por galón (`mpg`):

```
# Correlación de Pearson entre 2 variables
cor(dat$hp, dat$mpg)
```

```
## [1] -0.7761684
```

Hay que fijarse en que la correlación entre las variables X e Y es igual a la correlación entre las variables Y y X , por lo que el orden de las variables en la función `cor()` no importa.

La función `cor()` calcula por defecto la correlación de Pearson, por lo que si se quiere calcular la correlación por otro método, se puede agregar el argumento `method = "spearman"` a la función `cor()`:

```
# Correlación de Spearman entre 2 variables
cor(dat$hp, dat$mpg,
    method = "spearman")
```

```
## [1] -0.8946646
```

Hay varios métodos de correlación (se puede consultar la ayuda de la función para saber más `?cor`):

- **Pearson** se usa a menudo para variables *cuantitativas continuas* que tienen una relación lineal.

- **Spearman** (es similar a Pearson pero se basa en los valores ordenados para cada variable en lugar de en los datos brutos) se usa a menudo para evaluar relaciones que involucran variables cualitativas ordinales en las que la relación sea parcialmente lineal.
- **Kendall** se calcula a partir del número de pares concordantes y discordantes, se utiliza a menudo para variables ordinales cualitativas.

La función `cor()` también permite calcular correlaciones para varios pares de variables a la vez:

```
# Correlaciones entre todas las variables
round(cor(dat),
      digits = 2 # redondeo a dos decimales
    )
```

```
##      mpg   cyl  disp    hp  drat    wt  qsec  gear  carb
## mpg   1.00 -0.85 -0.85 -0.78  0.68 -0.87  0.42  0.48 -0.55
## cyl  -0.85  1.00  0.90  0.83 -0.70  0.78 -0.59 -0.49  0.53
## disp -0.85  0.90  1.00  0.79 -0.71  0.89 -0.43 -0.56  0.39
## hp   -0.78  0.83  0.79  1.00 -0.45  0.66 -0.71 -0.13  0.75
## drat  0.68 -0.70 -0.71 -0.45  1.00 -0.71  0.09  0.70 -0.09
## wt   -0.87  0.78  0.89  0.66 -0.71  1.00 -0.17 -0.58  0.43
## qsec  0.42 -0.59 -0.43 -0.71  0.09 -0.17  1.00 -0.21 -0.66
## gear  0.48 -0.49 -0.56 -0.13  0.70 -0.58 -0.21  1.00  0.27
## carb -0.55  0.53  0.39  0.75 -0.09  0.43 -0.66  0.27  1.00
```

La correlación varía de **-1 a 1**, de modo que el signo nos indica la dirección de la relación (aumentan a la vez o son opuestas) y el valor nos indica la fuerza de la relación (más fuerte cuanto más alejado de 0).

Una **correlación negativa** implica que las dos variables consideradas varían en **direcciones opuestas**, es decir, si una variable aumenta la otra disminuye y viceversa. Por otro lado, una **correlación positiva** implica que las dos variables consideradas varían en la **misma dirección**, es decir, si una variable aumenta, la otra aumenta y si una disminuye, la otra también disminuye.

En cuanto a la fuerza de la relación: cuanto **más extremo** es el coeficiente de correlación (cuanto más cerca de -1 o 1), **más fuerte es la relación**. Esto también significa que una **correlación cercana a 0** indica que las dos variables son **independientes**, es decir, a medida que una variable aumenta, no hay tendencia en la otra variable a disminuir o aumentar.

Por ejemplo, la correlación de Pearson entre caballos de potencia (**hp**) y millas por galón (**mpg**) encontrada es -0.78, lo que significa que las 2 variables varían en dirección opuesta. Esto tiene sentido, los automoviles con más caballos de potencia suelen a consumir más combustible (hacen menos millas con el mismo combustible que los automóviles más potentes). Por el contrario, de la matriz de correlación vemos que la correlación entre millas por galón (**mpg**) y el tiempo para conducir un cuarto de milla (**qsec**) es 0.42, lo que significa que los automóviles

rápidos (con un menor `qsec`) tienden a tener un peor rendimiento por galón (bajo `mpg`). De nuevo, esto tiene sentido, ya que los coches rápidos tienden a consumir más combustible.

2.3.3 Test de correlación

Volver una vez leída la sección sobre test de hipótesis.

Hay que tener en cuenta que el valor p se basa en el coeficiente de correlación y en el tamaño de la muestra. Cuanto mayor sea el tamaño de la muestra y más extrema será la correlación (más cercana a -1 o 1). Con un tamaño de muestra pequeño, es posible obtener una correlación *relativamente* grande en la muestra (según el coeficiente de correlación), pero aún así encontrar una correlación no significativamente diferente de 0 en la población (según la prueba de correlación). Por este motivo, se recomienda realizar siempre un test de correlación antes de interpretar un coeficiente de correlación para evitar conclusiones erróneas.

A diferencia de una matriz de correlación que indica los coeficientes de correlación entre algunos pares de variables en la muestra, se utiliza un test de correlación para probar si la correlación (ρ) entre dos variables es significativamente diferente de 0 o no en la *población*.

En realidad, un coeficiente de correlación diferente de 0 en la muestra no significa que la correlación sea **significativamente** diferente de 0 en la población. Esto debe probarse con un **test de hipótesis**.

Las hipótesis (nula y alternativa) para el test de correlación son las siguientes:

- $H_0: \rho = 0$ (si no existe una relación lineal entre las dos variables)
- $H_1: \rho \neq 0$ (si existe una relación lineal entre las dos variables)

A través de esta prueba de correlación, lo que realmente estamos probando es si:

- La muestra contiene evidencia suficiente para rechazar la hipótesis nula y concluir que el coeficiente de correlación no es igual a 0, por lo que la relación existe en la población.
- La muestra no contiene suficiente evidencia de que el coeficiente de correlación no sea igual a 0, por lo que en este caso no rechazamos la hipótesis nula de no-relación entre las variables de la población.

Supongamos que queremos probar si el ratio del eje trasero (`drat`) está correlacionado con el tiempo necesario para conducir 1/4 de milla (`qsec`):

```
# Test de correlación de Pearson
test <- cor.test(dat$drat, dat$qsec)
test

##
## Pearson's product-moment correlation
##
```

```
## data: dat$drat and dat$qsec
## t = 0.50164, df = 30, p-value = 0.6196
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.265947  0.426340
## sample estimates:
##          cor
## 0.09120476
```


El p -valor de la prueba de correlación entre estas 2 variables es 0.62. Al nivel de significancia del 5%, no se rechaza la hipótesis nula de no correlación. Por lo tanto, concluimos que no rechazamos la hipótesis de que no existe una relación lineal entre las 2 variables.¹

Esta prueba demuestra que incluso si el coeficiente de correlación es diferente de 0 (la correlación es 0.09 en la muestra), en realidad no es significativamente diferente de 0 en la población.

2.3.4 Visualizando correlaciones

Una buena forma de visualizar una correlación entre 2 variables es mediante un diagrama de dispersión. Por ejemplo:

```
# Diagrama de dispersión con R base
plot(dat$hp, dat$mpg)
```

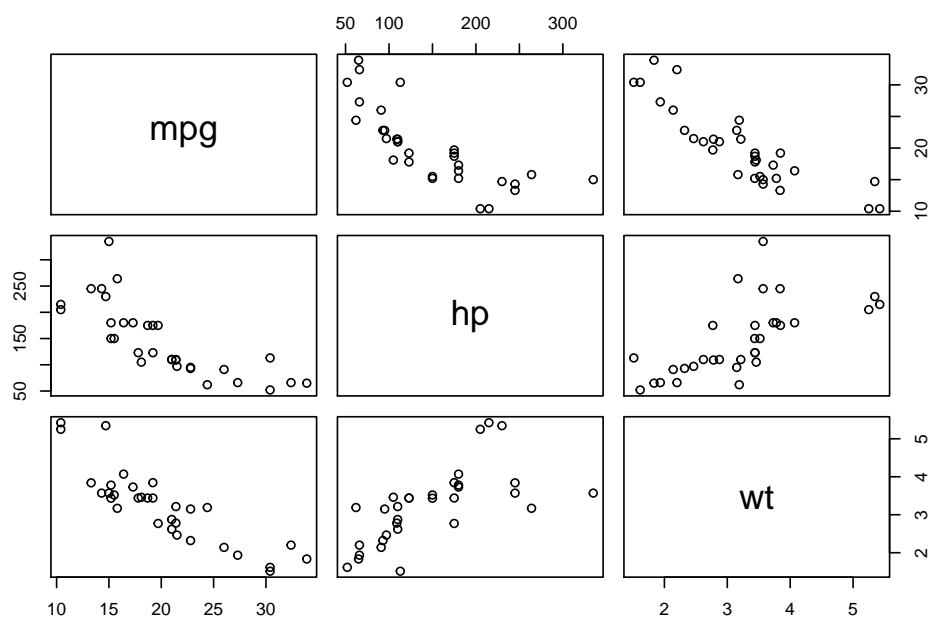


Para visualizar la relación entre más de 2 variables se puede usar la función `pair`

¹Es importante recordar que probamos una relación *lineal* entre las dos variables ya que usamos la correlación de Pearson. Puede darse el caso de que exista una relación entre las dos variables en la población, pero esta relación puede no ser lineal.

(). En este caso limitamos el ejemplo a tres variables:


```
# Múltiples diagramas de dispersión
pairs(dat[, c(1, 4, 6)])
```



Por otra parte, existen numerosas librerías de R que permiten generar este tipo de gráficos con distintas opciones. Por ejemplo con `ggplot2`:

```
# Diagrama de dispersión con ggplot2
library(ggplot2)


ggplot(dat) +
  aes(x = hp, y = mpg) +
  geom_point(colour = "#0c4c8a") +
  theme_minimal()
```



O representaciones más modernas como con la librería `corrplot`:

```
# improved correlation matrix
library(corrplot)

corrplot(cor(dat),
  method = "number",
  type = "upper" # show only upper side
)
```

2.4 Ejercicios

1. Estableced en clase un debate sobre variables de carácter territorial que consideréis que pueden estar correlacionadas y en qué medida.

Capítulo 3

Estadística inferencial

La **estadística descriptiva** es la rama de la estadística que tiene como objetivo **describir y resumir un conjunto de datos** de la mejor manera posible, es decir, con la menor pérdida de información posible. Con la estadística descriptiva no hay incertidumbre, porque describimos solo el grupo de observaciones en las que decidimos trabajar y no se intenta generalizar las características observadas o estudiar un grupo más grande a partir de un conjunto de datos limitado.

Por otro lado, **La estadística inferencial** es la rama de la estadística que utiliza una muestra aleatoria de datos tomados de una población para hacer inferencias, es decir, **sacar conclusiones sobre la *población* de interés**. En otras palabras, la información de la muestra se utiliza para hacer generalizaciones sobre el *parámetro* de interés en la población.

Las dos herramientas más importantes utilizadas en estadística inferencial son los test de hipótesis y los intervalos de confianza.

3.1 Distribuciones de probabilidad

Una distribución de probabilidad es una función que describe la probabilidad de obtener los posibles valores que puede asumir una variable aleatoria. En otras palabras, los valores de la variable varían según la distribución de probabilidad subyacente.

Supongamos que seleccionamos una muestra aleatoria de personas y medimos la altura de los sujetos. A medida que vamos midiendo las alturas, podemos crear una distribución de alturas. Este tipo de distribución es útil cuando necesita saber qué resultados son más probables, la dispersión de los valores potenciales y la probabilidad de resultados diferentes. Por lo tanto se puede utilizar distribuciones de probabilidad para realizar inferencias.

3.1.1 Funciones de R para distribuciones de probabilidad

R tiene varias funciones para trabajar con cada distribución de probabilidad. Hay un nombre de raíz, por ejemplo, el nombre de raíz para la distribución normal es `norm`. Esta raíz tiene como prefijo una de las letras:

- `p` para “probabilidad”, la función de distribución acumulativa.
- `q` para “cuantil”, el inverso de la función de distribución acumulativa.
- `d` para “densidad”, la función de densidad (p. f. o p. d. f.)
- `r` para “aleatorio”, una variable aleatoria que tiene la distribución especificada

Para la distribución normal, estas funciones son `pnorm`, `qnorm`, `dnorm` y `rnorm`, mientras que para la distribución binomial, estas funciones son `dbinom`, `qbinom`, `dbinom` y `rbinom`.

Para una distribución continua (como la normal), las funciones más útiles para resolver problemas que involucran cálculos de probabilidad son las funciones `p` y `q`, porque la densidad por la función `d` solo se puede usar para calcular probabilidades a través de integrales.

Para una distribución discreta (como la binomial), la función `d` calcula la densidad (p. F.), Que en este caso es una probabilidad

$$f(x) = P(X = x)$$

y por lo tanto es útil para calcular probabilidades.

R tiene funciones para manejar muchas distribuciones de probabilidad. La siguiente tabla proporciona los nombres de las funciones para cada distribución y un enlace a la documentación en línea que es la referencia autorizada sobre cómo se utilizan las funciones. Pero no lea la documentación en línea todavía. Primero, pruebe los ejemplos de las secciones que siguen a la tabla.

```
library(readr) probability_distribution_functions_in_r <- read_csv("probability-
distribution-functions-in-r.csv")
```

Funciones para distribución de probabilidades in R.

Distribution

p

q

d

r

Beta

pbeta

qbeta

dbeta

rbeta

Binomial

pbinom

qbinom

dbinom

rbinom

Cauchy

pcauchy

qcauchy

dcauchy

rcauchy

Chi-Square

pchisq

qchisq

dchisq

rchisq

Exponential

pexp

qexp

dexp

rexp

F

pf

qf

df

rf

Gamma

pgamma

qgamma

dgamma

rgamma

Geometric

pgeom

qgeom

dgeom

rgeom

Hypergeometric

phyper

qhyper

dhyper

rhyper

Logistic

plogis

qlogis

dlogis

rlogis

Log Normal

plnorm

qlnorm

dlnorm

rlnorm

Negative Binomial

pnbinom

qnbinom

dnbinom

rnbinom

Normal

pnorm

qnorm

dnorm

rnorm

Poisson

ppois

qpois

dpois

rpois

Student t

pt

qt

dt

rt

Studentized Range

ptukey

qtukey

dtukey

rtukey

Uniform

punif

qunif

dunif

runif

Weibull

pweibull

qweibull

dweibull

rweibull

Wilcoxon Rank Sum Statistic

pwilcox

qwilcox

dwilcox

rwilcox

Wilcoxon Signed Rank Statistic

psignrank

qsignrank

dsignrank

rsignrank

3.1.2 La distribución binomial

3.1.3 La distribución normal

3.2 Introduccion a los test de hipótesis

Primero cabe preguntarse por qué intentaríamos hacer inferencias sobre un parámetro de una población basada en una muestra, en lugar de simplemente recopilar datos para toda la población, calcular estadísticas que nos interesan y tomar decisiones basadas en eso. La principal razón por la que utilizamos una muestra en lugar de toda la población es porque recopilar datos sobre toda la población es más complicado o en ocasiones impracticable por varios motivos (complejidad, coste, limitación de tiempo, entre muchos otros motivos).¹

El objetivo general de una prueba de hipótesis es sacar conclusiones para confirmar o refutar una creencia sobre una población, basándonos en un grupo más pequeño de observaciones.

Las pruebas de hipótesis tienen muchas aplicaciones prácticas. Aquí ponemos algunos ejemplos:

1. Una media: supongamos que a un político le gustaría probar si el salario medio de los trabajadores españoles es diferente de 1200 euros.
2. Dos medias:
 - Muestras independientes: suponga que a un fisioterapeuta le gustaría probar la eficacia de un nuevo tratamiento midiendo el tiempo de respuesta medio (en segundos) para los pacientes de un grupo de control y los pacientes de un grupo de tratamiento, donde los pacientes de los dos grupos son diferentes.
 - Muestras pareadas: suponga que a un fisioterapeuta le gustaría probar la eficacia de un nuevo tratamiento midiendo el tiempo de respuesta medio (en segundos) antes y después de un tratamiento, donde los pacientes se miden dos veces, antes y después del tratamiento, por lo que los pacientes son lo mismo en las 2 muestras.

¹Por ejemplo, una investigación podría consistir en conocer si la población de la provincia de Tarragona está satisfecha con el nuevo plan de movilidad. Si pudiéramos preguntar a toda la población en un período de tiempo razonable, no haríamos ninguna estadística inferencial. No obstante, aún habría que decidir que preguntas se les hace para entender mejor el motivo de su grado de satisfacción, complicando y encareciendo aún más la encuesta.

3. Una proporción: supongamos que a un experto en política le gustaría comprobar si la proporción de ciudadanos que van a votar por un candidato específico es inferior al 30%.
4. Dos proporciones: suponga que a un médico le gustaría probar si la proporción de fumadores es diferente entre atletas profesionales y aficionados.
5. Una variación: suponga que un ingeniero quisiera probar si un voltímetro tiene una variabilidad menor que la impuesta por las normas de seguridad.
6. Dos variaciones: suponga que, en una fábrica, dos líneas de producción funcionan independientemente una de la otra. El gerente financiero quisiera probar si los costos del mantenimiento semanal de estas dos máquinas tienen la misma variación. Tenga en cuenta que a menudo también se realiza una prueba de dos varianzas para verificar la suposición de varianzas iguales, que se requiere para varias otras pruebas estadísticas, como la [prueba t de Student] (/ blog / student-st-test-in-r -y-a-mano-cómo-comparar-dos-grupos-bajo-diferentes-escenarios /) por ejemplo.

Por supuesto, hay muchísimas más aplicaciones potenciales y muchas preguntas de investigación pueden responderse gracias a una prueba de hipótesis.

Por lo general, **las pruebas de hipótesis se utilizan para responder preguntas de investigación en análisis confirmatorios**. Los análisis confirmatorios se refieren a análisis estadísticos donde las hipótesis — deducidas de la teoría — se definen de antemano (preferiblemente antes de la recopilación de datos). En este enfoque, la investigadora tiene una idea específica sobre las variables en consideración y está tratando de ver si su idea, especificada como hipótesis, está respaldada por datos.

Podemos utilizar al menos tres métodos diferentes para realizar una prueba de hipótesis comparando:

1. la estadística de prueba con el **valor crítico**.
2. el **p-valor** con el nivel de significancia α .
3. el parámetro objetivo con el **intervalo de confianza**.

Estos enfoques puede diferir en algunos aspectos pero tienen muchos puntos en común. El uso de uno u otro método es a menudo una cuestión de elección personal o de contexto.

Para los tres métodos, explicaré los pasos necesarios para realizar una prueba de hipótesis desde un punto de vista general y los ilustraré con la siguiente situación: $\hat{}$ [Puede ver más o menos pasos en otros artículos o libros de texto, dependiendo de si estos pasos son detallados o concisos. Sin embargo, la prueba de hipótesis debe seguir el mismo proceso independientemente del número de pasos].

Supongamos que un político quisiera comprobar si el salario medio de los trabajadores españoles es diferente de 1.200 euros. En la mayoría

de las pruebas de hipótesis, la prueba que vamos a utilizar como ejemplo a continuación requiere algunas condiciones. Dado que el objetivo del presente artículo es explicar una prueba de hipótesis, asumimos que se cumplen todos los supuestos.

3.2.1 Comparando la estadística de prueba con el valor crítico.

Este metodo consiste en reproducir los siguientes 4 pasos:

1. Establecer la **hipótesis nula y alternativa**
2. Calcular la **estadística de prueba**
3. Encontrar el **valor crítico**
4. **Concluir** e interpretar los resultados

3.2.1.1 Estableciendo la hipótesis nula y alternativa

Una prueba de hipótesis primero requiere una suposición sobre un fenómeno o hipótesis, que se deriva de la teoría y la pregunta de investigación.

Dado que una prueba de hipótesis se utiliza para confirmar o refutar una creencia previa, necesitamos **formular nuestra creencia de modo que haya una hipótesis nula y una alternativa**. Esas hipótesis deben ser **mútuamente excluyentes**, lo que significa que no pueden ser verdaderas al mismo tiempo. En el contexto, las hipótesis nula y alternativa son así:

- Hipótesis nula $H_0 : \mu = 1200$
- Hipótesis alternativa $H_1 : \mu \neq 1200$

Al plantear la hipótesis nula y alternativa, tenga en cuenta los siguientes tres puntos:

1. *Siempre estamos interesados en la población y no en la muestra.* Esta es la razón por la que H_0 y H_1 siempre se escribirán en términos de población y no en términos de muestra (en este caso, μ y no \bar{x}).
2. *La suposición que nos gustaría probar es a menudo la hipótesis alternativa.* Si quisieramos probar si el salario medio de los trabajadores españoles es inferior a 1200 euros, habríamos establecido que $H_0 : \mu = 1200$ (o equivalentemente, $H_0 : \mu \geq 1200$) y $H_1 : \mu < 1200$. **No hay que confundir la hipótesis nula con la alternativa, o las conclusiones serán diametralmente opuestas.**
3. *La hipótesis nula es a menudo el status quo.* Por ejemplo, suponiendo que un empresario quiere probar si el nuevo logo de su marca es mejor valorado que el logo anterior. El *status quo* es que los dos logos sean igualmente valorados. Suponiendo que un valor mayor es mejor, entonces se escribirá $H_0 : \mu_{nuevo} = \mu_{viejo}$ (o equivalentemente, $H_0 : \mu_{nuevo} - \mu_{viejo} = 0$) y $H_1 : \mu_{nuevo} > \mu_{viejo}$ (o equivalentemente, $H_0 : \mu_{nuevo} - \mu_{viejo} > 0$). Por el contrario, si cuanto más bajo mejor, habríamos escrito $H_0 : \mu_{nuevo} = \mu_{viejo}$

(o equivalentemente, $H_0 : \mu_{nuevo} - \mu_{viejo} = 0$) y $H_1 : \mu_{nuevo} < \mu_{viejo}$ (o equivalentemente, $H_0 : \mu_{nuevo} - \mu_{viejo} < 0$).

3.2.1.2 Calcular la estadística de prueba

La **estadística de prueba** (o **t-stat**) es una métrica que indica **qué tan extremas son las observaciones en comparación con la hipótesis nula**. Cuanto mayor sea el t -stat (en valor absoluto), más extremas serán las observaciones.

Hay varias fórmulas para calcular el t -stat, con una fórmula para cada tipo de prueba de hipótesis: una o dos medias, una o dos proporciones, una o dos varianzas. Esto significa que hay una fórmula para calcular el t -stat para una prueba de hipótesis en una media, otra fórmula para una prueba en dos medias, otra para una prueba en una proporción, etc.² La única dificultad en este segundo paso es elegir la fórmula adecuada. Tan pronto como se sepa qué fórmula utilizar según el tipo de prueba, simplemente debe aplicársele a los datos. Afortunadamente, las fórmulas para las pruebas de hipótesis en una y dos medias, y una y dos proporciones siguen la misma estructura.

Calcular la estadística de prueba para estas pruebas es similar a *escalar* una variable aleatoria (un proceso también conocido como “estandarización” o “normalización”) que consiste en restar la media de esa variable aleatoria y dividir el resultado por la desviación estándar:

$$Z = \frac{X - \mu}{\sigma}$$

Para estas 4 pruebas de hipótesis (una/dos medias y una/dos proporciones), calcular el estadístico de prueba es como escalar el estimador (calculado a partir de la muestra) correspondiente al parámetro de interés (en la población). Así que básicamente restamos el parámetro objetivo del estimador puntual y luego dividimos el resultado por el error estándar (que es equivalente a la desviación estándar, pero para un estimador).

Si esto no está claro, así es como se calcula la estadística de prueba (t_{obs}) en nuestro ejemplo (asumiendo que se desconoce la varianza de la población):

$$t_{obs} = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

dónde:

- \bar{x} es la media de la muestra (es decir, el estimador)
- μ es la media bajo la hipótesis nula (es decir, el parámetro objetivo)
- s es la desviación estándar de la muestra

²Incluso hay diferentes fórmulas dentro de cada tipo de prueba, dependiendo de si se cumplen o no algunos supuestos.

- n es el tamaño de la muestra
- $(\frac{s}{\sqrt{n}})$ es el error estándar

Suponiendo que en nuestro caso tenemos una media muestral de 1150 euros ($\bar{x} = 1150$), una desviación estándar muestral de 200 euros ($s = 200$) y un tamaño de muestra de 30 trabajadores ($n = 30$) y, teniendo en cuenta que la media poblacional (la media bajo la hipótesis nula) es 1200 euros ($\mu = 1200$), el t-stat quedaría así:

$$t_{obs} = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} = \frac{1150 - 1200}{\frac{200}{\sqrt{30}}} = -1.369306$$

Aunque las fórmulas son diferentes según el parámetro que esté probando, el valor encontrado para la estadística de prueba nos da una indicación de cuán extremas son nuestras observaciones.

Recordemos este valor de -1.369306 porque se volverá a utilizar al final de este test para compararlo con el valor crítico.

3.2.1.3 Encontrando el valor crítico

Aunque el **t-stat** nos da una indicación como de extremas son nuestras observaciones, necesitamos comparar este valor con un umbral o **valor crítico**, que viene dado por una **distribución de probabilidad**.

De la misma manera que la fórmula para calcular el **t-stat** es diferente para cada parámetro de interés, la distribución de probabilidad subyacente en la que se basa el *valor crítico* también es diferente para cada parámetro objetivo. Esto significa que, además de elegir la fórmula apropiada para calcular el **t-stat**, también necesitamos seleccionar la distribución de probabilidad apropiada dependiendo del parámetro que estemos probando.

Afortunadamente, solo hay 4 distribuciones de probabilidad diferentes para las pruebas de hipótesis cubiertas aquí (recordemos que son una/dos medias, una/dos proporciones y una/dos varianzas):

1. Distribución normal estándar:
 - prueba en una y dos medias con varianzas de población conocidas.
 - prueba en dos muestras donde se conoce la varianza de la diferencia entre las 2 muestras σ_D^2
 - prueba en una y dos proporciones (dado que se cumplen algunos supuestos).
2. Distribución de Student:
 - prueba en una y dos medias con *varianza(s) de población desconocida(s).
 - prueba en dos muestras donde la varianza de la diferencia entre las 2 muestras σ_D^2 es *desconocida*.
3. Distribución Chi-cuadrado:

- prueba en una varianza.
4. Distribution de fisher:
- prueba en dos varianzas.

Cada distribución de probabilidad tiene sus propios parámetros, definiendo su forma y/o ubicación. Los parámetros de una distribución de probabilidad pueden verse como si fuesen marcadores de ADN; lo que significa que la distribución está completamente definida por su(s) parámetro(s).

Volviendo a nuestra investigación, la distribución de probabilidad subyacente de una prueba en una media es la distribución Normal estándar o de Student, dependiendo de si la varianza de la *población* (no la varianza de la muestra) es conocida o no:

- Si se conoce la varianza de la población \rightarrow , se usa la distribución Normal estándar
- Si la varianza de la población es *desconocida* \rightarrow , se utiliza la distribución de Student

Si no se proporciona explícitamente la varianza de la población, se puede suponer que es desconocida, ya que no se puede calcular basándonos en una muestra. Si pudiera calcularlo, eso significaría que tiene acceso a toda la población y, en este caso, no tiene sentido realizar una prueba de hipótesis (simplemente podría usar algunas estadísticas descriptivas para confirmar o refutar su creencia dicha hipótesis. En nuestro ejemplo, no se especifica la varianza de la población, por lo que se supone que es desconocida. Por lo tanto, usaremos la distribución de Student.

La distribución Student tiene un parámetro que la define: el número de grados de libertad. El número de grados de libertad depende del tipo de prueba de hipótesis. Por ejemplo, el número de grados de libertad para una prueba en una media es igual al número de observaciones menos uno ($n - 1$). Sin ir demasiado lejos en los detalles, el -1 proviene del hecho de que hay una cantidad que se estima (es decir, la media). Siendo el tamaño de la muestra igual a 30 en nuestro ejemplo, los grados de libertad son iguales a $n - 1 = 30 - 1 = 29$.

Por último, para encontrar el valor crítico también es necesario conocer el **nivel de significancia** α , que es la **probabilidad de rechazar erróneamente la hipótesis nula aunque en realidad sea verdadera**. En este sentido, es un error de tipo I (en contraposición al error de tipo II) que aceptamos para poder sacar conclusiones sobre una población a partir de un subconjunto de ella.

En muchas aplicaciones el nivel de significancia se suele establecer en el 5%. En cambio, en algunos campos (como la medicina o la ingeniería, entre otros), el nivel de significancia también se establece a veces en el 1% para disminuir la tasa de error. Es mejor especificar el nivel de significancia *antes* de realizar una prueba de hipótesis para evitar la tentación de establecer el nivel de significancia de acuerdo con los resultados (la tentación es aún mayor cuando los resultados están al borde de ser significativos). En nuestro caso, tomamos $\alpha = 5\% = 0.05$.

Además, queremos probar si el salario medio de los trabajadores españoles es **diferente** de 1200 euros. Si quisiéramos probar que el salario medio fuera inferior a 1200 euros ($H_1 : \mu < 1200$) o superior a 1200 (\$ H_1: >1200\$), habríamos realizado una prueba unilateral. Asegúrese de realizar la prueba correcta (bilateral o unilateral) porque tiene un impacto en cómo encontrar el valor crítico.

Ahora que conocemos la distribución apropiada (distribución de Student), su parámetro (grados de libertad (gl) = 29), el nivel de significancia ($\alpha = 0.05$) y la dirección (bilateral), tenemos todo lo que necesitamos para calcular el valor crítico. Podríamos localizar este valor en la tabla estadística correspondiente o directamente lo podríamos calcular con R.


Al observar la fila $df = 29$ y la columna $t_{.025}$ en la tabla de distribución de Student, encontramos un valor crítico de:

$$t_{n-1;\alpha/2} = t_{29;0.025} = 2.04523$$

Tomamos $t_{\alpha/2} = t_{.025}$ y no $t_{\alpha} = t_{.05}$ ya que el nivel de significancia es 0.05 y estamos haciendo una prueba bilateral (de dos lados; \$ H_1: 1200\$), por lo que la tasa de error de 0.05 debe dividirse en 2 para encontrar el valor crítico a la derecha de la distribución. Dado que la distribución de Student es simétrica, el valor crítico a la izquierda de la distribución es simplemente: -2.04523.

Visualmente, la tasa de error de 0.05 se divide en dos partes:

- 0,025 a la izquierda de -2,04523 y
- 0,025 a la derecha de 2,04523



Al igual que en el apartado anterior, cabe recordar estos valores críticos de -2,045 y 2,045 el último paso.

Las áreas sombreadas en rojo en el gráfico anterior también se conocen como regiones de rechazo.

Estos valores críticos también se pueden encontrar en R, gracias a la función `qt()`:

```
qt(0.025, df = 29, lower.tail = TRUE)
```

```
## [1] -2.04523
```

```
qt(0.025, df = 29, lower.tail = FALSE)
```

```
## [1] 2.04523
```

Como se ha visto en el tema sobre distribuciones de probabilidad, la función `qt()` se usa para la distribución de Student (q significa cuantil y t para Student). Cabe recordar que hay otras funciones que acompañan a las diferentes distribuciones:

- `qnorm()` para la distribución Normal
- `qchisq()` para la distribución Chi-cuadrado
- `qf()` para la distribución de Fisher

3.2.1.4 Conclusión e interpretación de los resultados

Las únicas dos posibilidades al concluir una prueba de hipótesis son:

1. Rechazo de la hipótesis nula, o
2. No rechazo de la hipótesis nula


En nuestro ejemplo sobre los salarios de los españoles, recordamos que hemos determinado que el:

- el **t-stat** es -1.369306, y
- los valores críticos son -2.04523 y 2.04523

Recordemos que:

- el **t-stat** da una indicación de cuán extrema es nuestra muestra en comparación con la hipótesis nula
- los valores críticos son el umbral a partir del cual el t-stat se considera *demasiado* extremo

Para comparar el **t-stat** con los valores críticos de manera gráfica:



Los dos valores críticos forman las regiones de rechazo (las áreas sombreadas en rojo):

- de $-\infty$ a -2.045, y
- de 2.045 a ∞

Si el *t-stat* se encuentra dentro de una de estas regiones, rechazamos la hipótesis nula. Por el contrario, si *t-stat* *no* se encuentra dentro de ninguna de las regiones, no rechazamos la hipótesis nula.

Como podemos ver en el gráfico anterior, el *t-stat* es menos extremo que el valor crítico. En conclusión, no rechazamos la hipótesis nula de que $\mu = 1200$.

Esta es la conclusión en términos estadísticos, pero no tienen sentido sin una interpretación adecuada. Por tanto, es una buena práctica interpretar también el resultado en el contexto del problema:

Con un nivel de significancia del 5%, no rechazamos la hipótesis de que el salario medio de los trabajadores españoles es de 1200 euros.

¿Qué significa esto realmente? Dicho de otro modo:

“nosotros *no rechazamos* la hipótesis nula” y “nosotros *no rechazamos* la hipótesis de que el salario medio de los trabajadores españoles es igual a 1200 euros”. No escribimos “*aceptamos o estamos de acuerdo con* la hipótesis nula” ni “el salario medio de los trabajadores españoles es de 1200 euros”.

En los test de hipótesis, llegamos a una conclusión sobre la población a partir de una muestra. Por tanto, siempre existe cierta incertidumbre y no podemos

decir que estemos seguros al 100% de que nuestra conclusión sea correcta.

Quizás sea el caso de que el salario medio de los trabajadores españoles sea en realidad diferente a 1200 euros, pero **no lo pudimos demostrar** con los datos disponibles. Si tuviéramos más observaciones hubiéramos rechazado la hipótesis nula (dado que todo lo demás es igual, un tamaño de muestra más grande implica un **t-stat** más extremo). O puede darse el caso de que, incluso con más observaciones, no hubiéramos rechazado la hipótesis nula porque el salario de los trabajadores españoles en realidad se acerca a los 1200 euros. Con los datos disponibles no podemos distinguir entre estas dos posibilidades. Simplemente debemos admitir que no encontramos suficiente evidencia en contra de la hipótesis de partida, pero tampoco concluimos que la media sea igual a 1200 euros.

3.2.2 Comparando el p -valor con el nivel de significancia

α

Este método consiste en los siguientes pasos:

1. Enunciar las **hipótesis nula y alternativa**
2. Calcular la **estadística de prueba** (**t-stat**).
3. Calcular el **p -valor**
4. **Concluir** e interpretar los resultados

En este segundo método que utiliza el valor p , los dos primeros pasos son similares a los del primer método, mientras que la interpretación de los resultados tiene algunos puntos en común.

3.2.2.1 Establecer las hipótesis

Las hipótesis de investigación (nula y alternativa) siguen siendo las mismas:

- $H_0 : \mu = 1200$
- $H_1 : \mu \neq 1200$

3.2.2.2 Calcular la estadística de prueba

Cabe recordar que la fórmula del estadístico t es diferente según el tipo de prueba de hipótesis (una o dos medias, una o dos proporciones, una o dos varianzas). En nuestro caso de una sola media con varianza desconocida, tenemos que:

$$t_{obs} = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} = \frac{1150 - 1200}{\frac{200}{\sqrt{30}}} = -1.369306$$

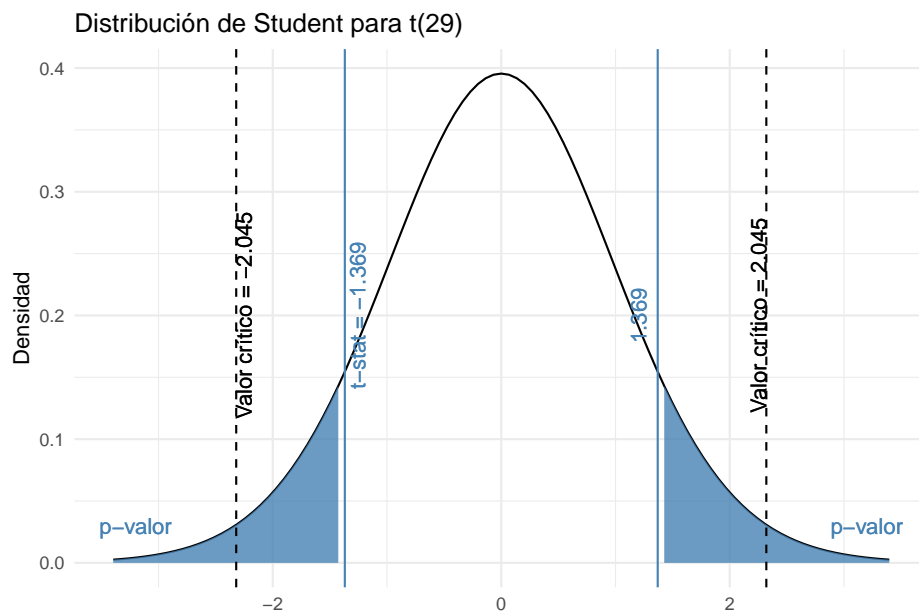
3.2.2.3 Calculo del valor p

El **p -valor** es la probabilidad (de 0 a 1) de observar una muestra al menos tan extrema como la que observamos si la hipótesis nula fuera cierta. Dicho de otro

modo: **¿cómo de probable es la hipótesis nula?**. También se define como el nivel de significancia más pequeño para el cual los datos indican el rechazo de la hipótesis nula.

Formalmente, el valor p es el área más allá del estadístico de prueba. Como estamos haciendo una prueba bidireccional, el valor p es, por lo tanto, la suma del área por encima de 1,369306 y por debajo de -1,369306.

Visualmente, el valor p es la suma de las dos áreas sombreadas en azul en la siguiente gráfica:



El valor p se puede obtener también con tablas estadísticas o es posible calcularlo con precisión en R con la función `pt()`:

```
p_val <- pt(-1.369306, df = 29, lower.tail = TRUE) + pt(1.369306, df = 29, lower.tail = FALSE)
p_val
```

```
## [1] 0.1814156
```

```
# Que es lo mismo que...
```

```
p_val <- 2 * pt(1.369306, df = 29, lower.tail = FALSE)
p_val
```

```
## [1] 0.1814156
```

El valor p es 0.1814, que indica que hay un 18.14% de probabilidad de observar una muestra al menos tan extrema como la observada si el hipótesis nula eran verdaderas. Esto ya nos da una pista sobre si nuestro t -stat es demasiado extremo o no (y, por lo tanto, si nuestra hipótesis nula es probable o no).

Como la función `qt()` para encontrar el valor crítico, usamos `pt()` para encontrar el valor p porque la distribución subyacente es la distribución de Student. En otros casos se utilizarían las funciones `pnorm()`, `pchisq()` y `pf()` para las otras distribuciones mencionadas anteriormente (Normal, Chi-cuadrado y Fisher).

3.2.2.4 Concluir e interpretar los resultados

Finalmente, hay que comparar el valor p que acabamos de calcular con el nivel de significancia α . Como para todas las pruebas estadísticas:

- Si el **p -valor es menor** que α ($p\text{-valor} < 0.05$), entonces H_0 es poco probable \rightarrow **rechazamos** la hipótesis nula.
- Si el **p -valor es mayor que o igual** a α ($p\text{-valor} \geq 0.05$), entonces H_0 es probable \rightarrow **no podemos rechazar** la hipótesis nula.

No importa si tomamos en consideración el p -valor exacto (es decir, 0.1814) o el acotado ($0.05 < p\text{-valor} < 0.10$), es mayor que 0.05, entonces no rechazamos la hipótesis nula. En el contexto del problema, no rechazamos la hipótesis nula de que el salario medio de los trabajadores españoles es igual a 1200 euros.

El resultado obtenido ha sido el mismo que en el primer método. Evidentemente, debería dar lo mismo si se usan los mismos datos y con el mismo nivel de significancia.

3.2.3 Comparación del parámetro objetivo con el intervalo de confianza

Este método consiste en calcular primero el intervalo de confianza y comparar sobre éste el parámetro objetivo (el parámetro bajo la hipótesis nula). Podemos distinguir tres pasos:

1. Enunciar las **hipótesis nula y alternativa**
2. Calcular el **intervalo de confianza**
3. **Concluir** e interpretar los resultados

También se pueden apreciar varias similitudes con los métodos anteriores.

3.2.3.1 Enunciar las hipótesis

Nuevamente, las hipótesis nula y alternativa siguen siendo las mismas:

- $H_0 : \mu = 1200$
- $H_1 : \mu \neq 1200$

3.2.3.2 Calcular el intervalo de confianza

Al igual que los test de hipótesis, los intervalos de confianza son una herramienta bien conocida en la estadística inferencial. El **intervalo de confianza** es un

procedimiento de estimación que produce un **intervalo que contiene el parámetro verdadero con una cierta probabilidad**.

De la misma manera que existe una fórmula para cada tipo de prueba de hipótesis al calcular las estadísticas de la prueba, existe una fórmula para cada tipo de intervalo de confianza. La fórmula para calcular un intervalo de confianza en una media μ (con varianza poblacional desconocida):

$$(1 - \alpha)\% \text{IC para } \mu = \bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$$

donde $t_{\alpha/2, n-1}$ se encuentra en la tabla de distribución de Student o se puede calcular con R (y es igual al valor crítico encontrado en el primer método).

Dados nuestros datos y con $\alpha = 0.05$, tenemos que:

$$\begin{aligned} 95\% \text{ IC para } \mu &= \bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}} \\ &= 1150 \pm 2.045 \frac{200}{\sqrt{30}} \\ &= [1075, 33; 1224, 67] \end{aligned}$$

El intervalo de confianza del 95% para μ es $[1075, 33; 1224, 67]$ euros. **¿Qué significa este intervalo de confianza del 95%?**

Sabemos que este procedimiento de estimación tiene una probabilidad del 95% de producir un intervalo que contenga la media verdadera μ . En otras palabras, **si construimos muchos intervalos de confianza** (con diferentes muestras del mismo tamaño), **el 95% de ellos incluirá la media de la población** (el verdadero parámetro). Del mismo modo el 5% de estos intervalos de confianza no cubrirán la media real.

Si desea disminuir este último porcentaje, puede disminuir el nivel de significancia (por ejemplo $\alpha = 0.01$). En igualdad de condiciones, esto disminuirá el rango del intervalo de confianza y, por lo tanto, aumentará la probabilidad de que incluya el parámetro verdadero.

3.2.3.3 Conclusión e interpretación de los resultados

Finalmente, hay comparar el intervalo de confianza con el valor del parámetro objetivo (el valor cuestionado por la hipótesis nula):

- Si el **intervalo de confianza no incluye** el valor hipotético, H_0 es poco probable \rightarrow **rechazamos** la hipótesis nula.
- Si el **intervalo de confianza incluye** el valor hipotético, H_0 es probable \rightarrow , **no rechazamos** la hipótesis nula

En nuestro ejemplo:

- el valor hipotético es 1200 (desde $H_0: = 1200\$$)

- 1200 se incluye en el intervalo de confianza del 95%, ya que va de 1075,33 a 1224,67 euros
- Entonces **no rechazamos** la hipótesis nula de que el salario medio de los trabajadores españoles sea de 1200 euros.

Por supuesto, la conclusión es equivalente a la que se había llegado por los otros dos métodos. Esto debe ser así, ya que usamos los mismos datos y el mismo nivel de significancia α para los tres métodos.

Let's load all the packages needed for this chapter (this assumes you've already installed them). Recall from our discussion in Section ?? that loading the `tidyverse` package by running `library(tidyverse)` loads the following commonly used data science packages all at once:

- `ggplot2` for data visualization
- `dplyr` for data wrangling
- `tidyr` for converting data to “tidy” format
- `readr` for importing spreadsheet data into R
- As well as the more advanced `purrr`, `tibble`, `stringr`, and `forcats` packages

If needed, read Section ?? for information on how to install and load R packages.

```
library(tidyverse)
library(readr)
library(infer)
library(moderndiver)
library(nycflights13)
library(ggplot2movies)
```

3.3 Promotions activity

Let's start with an activity studying the effect of gender on promotions at a bank.

3.3.1 Does gender affect promotions at a bank?

Say you are working at a bank in the 1970s and you are submitting your résumé to apply for a promotion. Will your gender affect your chances of getting promoted? To answer this question, we'll focus on data from a study published in the *Journal of Applied Psychology* in 1974. This data is also used in the *OpenIntro* series of statistics textbooks.

To begin the study, 48 bank supervisors were asked to assume the role of a hypothetical director of a bank with multiple branches. Every one of the bank supervisors was given a résumé and asked whether or not the candidate on the résumé was fit to be promoted to a new position in one of their branches.

However, each of these 48 résumés were identical in all respects except one: the name of the applicant at the top of the résumé. Of the supervisors, 24 were randomly given résumés with stereotypically “male” names, while 24 of the supervisors were randomly given résumés with stereotypically “female” names. Since only (binary) gender varied from résumé to résumé, researchers could isolate the effect of this variable in promotion rates.

While many people today (including us, the authors) disagree with such binary views of gender, it is important to remember that this study was conducted at a time where more nuanced views of gender were not as prevalent. Despite this imperfection, we decided to still use this example as we feel it presents ideas still relevant today about how we could study discrimination in the workplace.

The `moderndive` package contains the data on the 48 applicants in the `promotions` data frame. Let’s explore this data by looking at six randomly selected rows:

```
promotions %>%
  sample_n(size = 6) %>%
  arrange(id)

## # A tibble: 6 x 3
##       id decision gender
##   <int> <fct>   <fct>
## 1    11 promoted male
## 2    26 promoted female
## 3    28 promoted female
## 4    36 not      male
## 5    37 not      male
## 6    46 not      female
```

The variable `id` acts as an identification variable for all 48 rows, the `decision` variable indicates whether the applicant was selected for promotion or not, while the `gender` variable indicates the gender of the name used on the résumé. Recall that this data does not pertain to 24 actual men and 24 actual women, but rather 48 identical résumés of which 24 were assigned stereotypically “male” names and 24 were assigned stereotypically “female” names.

Let’s perform an exploratory data analysis of the relationship between the two categorical variables `decision` and `gender`. Recall that we saw in Subsection ?? that one way we can visualize such a relationship is by using a stacked barplot.

```
ggplot(promotions, aes(x = gender, fill = decision)) +
  geom_bar() +
  labs(x = "Gender of name on résumé")
```

Observe in Figure 3.1 that it appears that résumés with female names were much less likely to be accepted for promotion. Let’s quantify these promotion rates by computing the proportion of résumés accepted for promotion for each



Figura 3.1: Barplot relating gender to promotion decision.

group using the `dplyr` package for data wrangling. Note the use of the `tally()` function here which is a shortcut for `summarize(n = n())` to get counts.

```
promotions %>%
  group_by(gender, decision) %>%
  tally()
```

```
## # A tibble: 4 x 3
## # Groups:   gender [2]
##   gender decision     n
##   <fct>   <fct>   <int>
## 1 male    not         3
## 2 male    promoted    21
## 3 female not         10
## 4 female promoted    14
```

So of the 24 résumés with male names, 21 were selected for promotion, for a proportion of $21/24 = 0.875 = 87.5\%$. On the other hand, of the 24 résumés with female names, 14 were selected for promotion, for a proportion of $14/24 = 0.583 = 58.3\%$. Comparing these two rates of promotion, it appears that résumés with male names were selected for promotion at a rate $0.875 - 0.583 = 0.292 = 29.2\%$ higher than résumés with female names. This is suggestive of an advantage for résumés with a male name on it.

The question is, however, does this provide *conclusive* evidence that there is gender discrimination in promotions at banks? Could a difference in promotion rates of 29.2% still occur by chance, even in a hypothetical world where no gender-based discrimination existed? In other words, what is the role of *sampling variation* in this hypothesized world? To answer this question, we'll again rely on a computer to run *simulations*.

3.3.2 Shuffling once

First, try to imagine a hypothetical universe where no gender discrimination in promotions existed. In such a hypothetical universe, the gender of an applicant would have no bearing on their chances of promotion. Bringing things back to our `promotions` data frame, the `gender` variable would thus be an irrelevant

label. If these **gender** labels were irrelevant, then we could randomly reassign them by “shuffling” them to no consequence!

To illustrate this idea, let’s narrow our focus to 6 arbitrarily chosen résumés of the 48 in Table 3.3.2. The **decision** column shows that 3 résumés resulted in promotion while 3 didn’t. The **gender** column shows what the original gender of the résumé name was.

However, in our hypothesized universe of no gender discrimination, gender is irrelevant and thus it is of no consequence to randomly “shuffle” the values of **gender**. The **shuffled_gender** column shows one such possible random shuffling. Observe in the fourth column how the number of male and female names remains the same at 3 each, but they are now listed in a different order.

One example of shuffling gender variable

résumé number

decision

gender

shuffled gender

1

not

male

male

2

not

female

male

3

not

female

female

4

promoted

male

female

5

promoted
male
female
6
promoted
female
male

Again, such random shuffling of the gender label only makes sense in our hypothesized universe of no gender discrimination. How could we extend this shuffling of the gender variable to all 48 résumés by hand? One way would be by using standard deck of 52 playing cards, which we display in Figure ??.

Since half the cards are red (diamonds and hearts) and the other half are black (spades and clubs), by removing two red cards and two black cards, we would end up with 24 red cards and 24 black cards. After shuffling these 48 cards as seen in Figure ??, we can flip the cards over one-by-one, assigning “male” for each red card and “female” for each black card.

We’ve saved one such shuffling in the `promotions_shuffled` data frame of the `moderndive` package. If you compare the original `promotions` and the shuffled `promotions_shuffled` data frames, you’ll see that while the `decision` variable is identical, the `gender` variable has changed.

Let’s repeat the same exploratory data analysis we did for the original `promotions` data on our `promotions_shuffled` data frame. Let’s create a barplot visualizing the relationship between `decision` and the new shuffled `gender` variable and compare this to the original unshuffled version in Figure 3.2.

```
ggplot(promotions_shuffled,
       aes(x = gender, fill = decision)) +
  geom_bar() +
  labs(x = "Gender of résumé name")
```

```
## `summarise()` regrouping output by 'gender' (override with `.groups` argument)
## `summarise()` regrouping output by 'gender' (override with `.groups` argument)
```

It appears the difference in “male names” versus “female names” promotion rates is now different. Compared to the original data in the left barplot, the new “shuffled” data in the right barplot has promotion rates that are much more similar.

Let’s also compute the proportion of résumés accepted for promotion for each group:

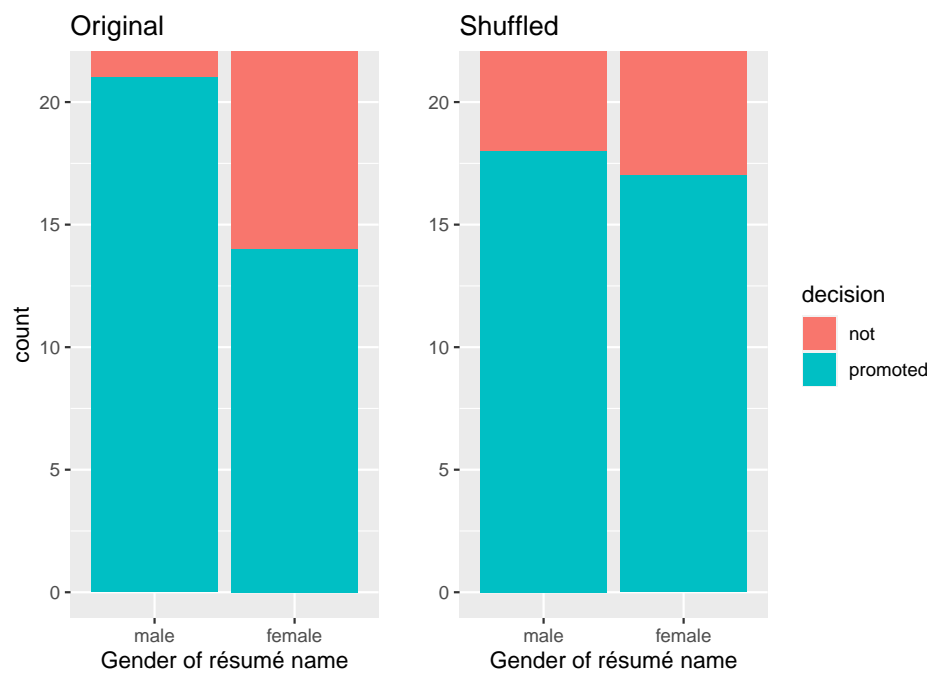


Figura 3.2: Barplots of relationship of promotion with gender (left) and shuffled gender (right).

```
promotions_shuffled %>%
  group_by(gender, decision) %>%
  tally() # Same as summarize(n = n())
```

```
## # A tibble: 4 x 3
## # Groups:   gender [2]
##   gender decision     n
##   <fct> <fct>    <int>
## 1 male   not         6
## 2 male   promoted    18
## 3 female not         7
## 4 female promoted    17
```

So in this hypothetical universe of no discrimination, $18/24 = 0.75 = 75\%$ of “male” résumés were selected for promotion. On the other hand, $17/24 = 0.708 = 70.8\%$ of “female” résumés were selected for promotion.

Let’s next compare these two values. It appears that résumés with stereotypically male names were selected for promotion at a rate that was $0.75 - 0.708 = 0.042 = 4.2\%$ different than résumés with stereotypically female names.

Observe how this difference in rates is not the same as the difference in rates of $0.292 = 29.2\%$ we originally observed. This is once again due to *sampling variation*. How can we better understand the effect of this sampling variation? By repeating this shuffling several times!

3.3.3 Shuffling 16 times

We recruited 16 groups of our friends to repeat this shuffling exercise. They recorded these values in a shared spreadsheet; we display a snapshot of the first 10 rows and 5 columns in Figure ??.

For each of these 16 columns of *shuffles*, we computed the difference in promotion rates, and in Figure 3.3 we display their distribution in a histogram. We also mark the observed difference in promotion rate that occurred in real life of $0.292 = 29.2\%$ with a dark line.

Before we discuss the distribution of the histogram, we emphasize the key thing to remember: this histogram represents differences in promotion rates that one would observe in our *hypothesized universe* of no gender discrimination.

Observe first that the histogram is roughly centered at 0. Saying that the difference in promotion rates is 0 is equivalent to saying that both genders had the same promotion rate. In other words, the center of these 16 values is consistent with what we would expect in our hypothesized universe of no gender discrimination.

However, while the values are centered at 0, there is variation about 0. This




Figura 3.3: Distribution of shuffled differences in promotions.

is because even in a hypothesized universe of no gender discrimination, you will still likely observe small differences in promotion rates because of chance *sampling variation*. Looking at the histogram in Figure 3.3, such differences could even be as extreme as -0.292 or 0.208.

Turning our attention to what we observed in real life: the difference of 0.292 = 29.2% is marked with a vertical dark line. Ask yourself: in a hypothesized world of no gender discrimination, how likely would it be that we observe this difference? While opinions here may differ, in our opinion not often! Now ask yourself: what do these results say about our hypothesized universe of no gender discrimination?

3.3.4 What did we just do?

What we just demonstrated in this activity is the statistical procedure known as *hypothesis testing* using a *permutation test*. The term “permutation” is the mathematical term for “shuffling”: taking a series of values and reordering them randomly, as you did with the playing cards.

In fact, permutations are another form of *resampling*, like the bootstrap method you performed in Chapter ???. While the bootstrap method involves resampling *with* replacement, permutation methods involve resampling *without* replacement.

Think of our exercise involving the slips of paper representing pennies and the hat in Section ??: after sampling a penny, you put it back in the hat. Now think of our deck of cards. After drawing a card, you laid it out in front of you, recorded the color, and then you *did not* put it back in the deck.

In our previous example, we tested the validity of the hypothesized universe of no gender discrimination. The evidence contained in our observed sample of 48 résumés was somewhat inconsistent with our hypothesized universe. Thus, we would be inclined to *reject* this hypothesized universe and declare that the evidence suggests there is gender discrimination.

Recall our case study on whether yawning is contagious from Section ?. The previous example involves inference about an unknown difference of population proportions as well. This time, it will be $p_m - p_f$, where p_m is the population proportion of résumés with male names being recommended for promotion and p_f is the equivalent for résumés with female names. Recall that this is one of the scenarios for inference we've seen so far in Table 3.3.4.

Scenarios of sampling for inference

Scenario

Population parameter

Notation

Point estimate

Symbol(s)

1

Population proportion

p

Sample proportion

\hat{p}

2

Population mean

μ

Sample mean

\bar{x} or $\hat{\mu}$

3

Difference in population proportions

$p_1 - p_2$

Difference in sample proportions

$$\hat{p}_1 - \hat{p}_2$$

So, based on our sample of $n_m = 24$ “male” applicants and $n_w = 24$ “female” applicants, the *point estimate* for $p_m - p_f$ is the *difference in sample proportions* $\hat{p}_m - \hat{p}_f = 0.875 - 0.583 = 0.292 = 29.2\%$. This difference in favor of “male” résumés of 0.292 is greater than 0, suggesting discrimination in favor of men.

However, the question we asked ourselves was “is this difference meaningfully greater than 0?”. In other words, is that difference indicative of true discrimination, or can we just attribute it to *sampling variation*? Hypothesis testing allows us to make such distinctions.

3.4 Understanding hypothesis tests

Much like the terminology, notation, and definitions relating to sampling you saw in Section ??, there are a lot of terminology, notation, and definitions related to hypothesis testing as well. Learning these may seem like a very daunting task at first. However, with practice, practice, and more practice, anyone can master them.

First, a **hypothesis** is a statement about the value of an unknown population parameter. In our résumé activity, our population parameter of interest is the difference in population proportions $p_m - p_f$. Hypothesis tests can involve any of the population parameters in Table ?? of the five inference scenarios we’ll cover in this book and also more advanced types we won’t cover here.

Second, a **hypothesis test** consists of a test between two competing hypotheses: (1) a **null hypothesis** H_0 (pronounced “H-naught”) versus (2) an **alternative hypothesis** H_A (also denoted H_1).

Generally the null hypothesis is a claim that there is “no effect” or “no difference of interest.” In many cases, the null hypothesis represents the status quo or a situation that nothing interesting is happening. Furthermore, generally the alternative hypothesis is the claim the experimenter or researcher wants to establish or find evidence to support. It is viewed as a “challenger” hypothesis to the null hypothesis H_0 . In our résumé activity, an appropriate hypothesis test would be:

$$\begin{aligned} H_0 &: \text{men and women are promoted at the same rate} \\ \text{vs } H_A &: \text{men are promoted at a higher rate than women} \end{aligned}$$

Note some of the choices we have made. First, we set the null hypothesis H_0 to be that there is no difference in promotion rate and the “challenger” alternative hypothesis H_A to be that there is a difference. While it would not be wrong in principle to reverse the two, it is a convention in statistical inference that the null hypothesis is set to reflect a “null” situation where “nothing is going on.” As we discussed earlier, in this case, H_0 corresponds to there being no difference

in promotion rates. Furthermore, we set H_A to be that men are promoted at a *higher* rate, a subjective choice reflecting a prior suspicion we have that this is the case. We call such alternative hypotheses *one-sided alternatives*. If someone else however does not share such suspicions and only wants to investigate that there is a difference, whether higher or lower, they would set what is known as a *two-sided alternative*.

We can re-express the formulation of our hypothesis test using the mathematical notation for our population parameter of interest, the difference in population proportions $p_m - p_f$:

$$\begin{aligned} H_0 : p_m - p_f &= 0 \\ \text{vs } H_A : p_m - p_f &> 0 \end{aligned}$$

Observe how the alternative hypothesis H_A is one-sided with $p_m - p_f > 0$. Had we opted for a two-sided alternative, we would have set $p_m - p_f \neq 0$. To keep things simple for now, we'll stick with the simpler one-sided alternative. We'll present an example of a two-sided alternative in Section ??.

Third, a **test statistic** is a *point estimate/sample statistic* formula used for hypothesis testing. Note that a sample statistic is merely a summary statistic based on a sample of observations. Recall we saw in Section ?? that a summary statistic takes in many values and returns only one. Here, the samples would be the $n_m = 24$ résumés with male names and the $n_f = 24$ résumés with female names. Hence, the point estimate of interest is the difference in sample proportions $\hat{p}_m - \hat{p}_f$.

Fourth, the **observed test statistic** is the value of the test statistic that we observed in real life. In our case, we computed this value using the data saved in the `promotions` data frame. It was the observed difference of $\hat{p}_m - \hat{p}_f = 0.875 - 0.583 = 0.292 = 29.2\%$ in favor of résumés with male names.

Fifth, the **null distribution** is the sampling distribution of the test statistic *assuming the null hypothesis H_0 is true*. Ooof! That's a long one! Let's unpack it slowly. The key to understanding the null distribution is that the null hypothesis H_0 is *assumed* to be true. We're not saying that H_0 is true at this point, we're only assuming it to be true for hypothesis testing purposes. In our case, this corresponds to our hypothesized universe of no gender discrimination in promotion rates. Assuming the null hypothesis H_0 , also stated as "Under H_0 ," how does the test statistic vary due to sampling variation? In our case, how will the difference in sample proportions $\hat{p}_m - \hat{p}_f$ vary due to sampling under H_0 ? Recall from Subsection ?? that distributions displaying how point estimates vary due to sampling variation are called *sampling distributions*. The only additional thing to keep in mind about null distributions is that they are sampling distributions *assuming the null hypothesis H_0 is true*.

In our case, we previously visualized a null distribution in Figure 3.3, which we re-display in Figure 3.4 using our new notation and terminology. It is the

distribution of the 16 differences in sample proportions our friends computed *assuming* a hypothetical universe of no gender discrimination. We also mark the value of the observed test statistic of 0.292 with a vertical line.




Figura 3.4: Null distribution and observed test statistic.

Sixth, the ***p*-value** is the probability of obtaining a test statistic just as extreme or more extreme than the observed test statistic *assuming the null hypothesis H_0 is true*. Double oooof! Let’s unpack this slowly as well. You can think of the *p*-value as a quantification of “surprise”: assuming H_0 is true, how surprised are we with what we observed? Or in our case, in our hypothesized universe of no gender discrimination, how surprised are we that we observed a difference in promotion rates of 0.292 from our collected samples assuming H_0 is true? Very surprised? Somewhat surprised?

The *p*-value quantifies this probability, or in the case of our 16 differences in sample proportions in Figure 3.4, what proportion had a more “extreme” result? Here, extreme is defined in terms of the alternative hypothesis H_A that “male” applicants are promoted at a higher rate than “female” applicants. In other words, how often was the discrimination in favor of men *even more* pronounced than $0.875 - 0.583 = 0.292 = 29.2\%$?

In this case, 0 times out of 16, we obtained a difference in proportion greater than or equal to the observed difference of $0.292 = 29.2\%$. A very rare (in fact, not occurring) outcome! Given the rarity of such a pronounced difference in promotion rates in our hypothesized universe of no gender discrimination, we’re inclined to *reject* our hypothesized universe. Instead, we favor the hypothesis stating there is discrimination in favor of the “male” applicants. In other words, we reject H_0 in favor of H_A .

Seventh and lastly, in many hypothesis testing procedures, it is commonly recommended to set the **significance level** of the test beforehand. It is denoted

by the Greek letter α (pronounced “alpha”). This value acts as a cutoff on the p -value, where if the p -value falls below α , we would “reject the null hypothesis H_0 .”

Alternatively, if the p -value does not fall below α , we would “fail to reject H_0 .” Note the latter statement is not quite the same as saying we “accept H_0 .” This distinction is rather subtle and not immediately obvious. So we’ll revisit it later in Section 3.6.

While different fields tend to use different values of α , some commonly used values for α are 0.1, 0.01, and 0.05; with 0.05 being the choice people often make without putting much thought into it. We’ll talk more about α significance levels in Section 3.6, but first let’s fully conduct the hypothesis test corresponding to our promotions activity using the `infer` package.

3.5 Conducting hypothesis tests

In Section ??, we showed you how to construct confidence intervals. We first illustrated how to do this using `dplyr` data wrangling verbs and the `rep_sample_n()` function from Subsection ?? which we used as a virtual shovel. In particular, we constructed confidence intervals by resampling with replacement by setting the `replace = TRUE` argument to the `rep_sample_n()` function.

We then showed you how to perform the same task using the `infer` package workflow. While both workflows resulted in the same bootstrap distribution from which we can construct confidence intervals, the `infer` package workflow emphasizes each of the steps in the overall process in Figure ?. It does so using function names that are intuitively named with verbs:

1. `specify()` the variables of interest in your data frame.
2. `generate()` replicates of bootstrap resamples with replacement.
3. `calculate()` the summary statistic of interest.
4. `visualize()` the resulting bootstrap distribution and confidence interval.

In this section, we’ll now show you how to seamlessly modify the previously seen `infer` code for constructing confidence intervals to conduct hypothesis tests. You’ll notice that the basic outline of the workflow is almost identical, except for an additional `hypothesize()` step between the `specify()` and `generate()` steps, as can be seen in Figure ?.

Furthermore, we’ll use a pre-specified significance level $\alpha = 0.05$ for this hypothesis test. Let’s leave discussion on the choice of this α value until later on in Section 3.6.

3.5.1 `infer` package workflow

1. specify variables

Recall that we use the `specify()` verb to specify the response variable and, if needed, any explanatory variables for our study. In this case, since we are interested in any potential effects of gender on promotion decisions, we set `decision` as the response variable and `gender` as the explanatory variable. We do so using `formula = response ~ explanatory` where `response` is the name of the response variable in the data frame and `explanatory` is the name of the explanatory variable. So in our case it is `decision ~ gender`.

Furthermore, since we are interested in the proportion of résumés "promoted", and not the proportion of résumés not promoted, we set the argument `success` to "promoted".

```
promotions %>%
  specify(formula = decision ~ gender, success = "promoted")
```

```
## Response: decision (factor)
## Explanatory: gender (factor)
## # A tibble: 48 x 2
##   decision gender
##   <fct>    <fct>
## 1 promoted male
## 2 promoted male
## 3 promoted male
## 4 promoted male
## 5 promoted male
## 6 promoted male
## 7 promoted male
## 8 promoted male
## 9 promoted male
## 10 promoted male
## # ... with 38 more rows
```

Again, notice how the `promotions` data itself doesn't change, but the `Response: decision (factor)` and `Explanatory: gender (factor)` *meta-data* do. This is similar to how the `group_by()` verb from `dplyr` doesn't change the data, but only adds "grouping" meta-data, as we saw in Section ??.

2. hypothesize the null

In order to conduct hypothesis tests using the `infer` workflow, we need a new step not present for confidence intervals: `hypothesize()`. Recall from Section 3.4 that our hypothesis test was

$$H_0 : p_m - p_f = 0$$

vs. $H_A : p_m - p_f > 0$

In other words, the null hypothesis H_0 corresponding to our “hypothesized universe” stated that there was no difference in gender-based discrimination rates. We set this null hypothesis H_0 in our `infer` workflow using the `null` argument of the `hypothesize()` function to either:

- "point" for hypotheses involving a single sample or
- "independence" for hypotheses involving two samples.

In our case, since we have two samples (the résumés with “male” and “female” names), we set `null = "independence"`.

```
promotions %>%
  specify(formula = decision ~ gender, success = "promoted") %>%
  hypothesize(null = "independence")
```

```
## Response: decision (factor)
## Explanatory: gender (factor)
## Null Hypothesis: independence
## # A tibble: 48 x 2
##   decision gender
##   <fct>    <fct>
## 1 promoted male
## 2 promoted male
## 3 promoted male
## 4 promoted male
## 5 promoted male
## 6 promoted male
## 7 promoted male
## 8 promoted male
## 9 promoted male
## 10 promoted male
## # ... with 38 more rows
```

Again, the data has not changed yet. This will occur at the upcoming `generate()` step; we’re merely setting meta-data for now.

Where do the terms "point" and "independence" come from? These are two technical statistical terms. The term “point” relates from the fact that for a single group of observations, you will test the value of a single point. Going back to the pennies example from Chapter ??, say we wanted to test if the mean year of all US pennies was equal to 1993 or not. We would be testing the value of a “point” μ , the mean year of *all* US pennies, as follows

$$H_0 : \mu = 1993$$

$$\text{vs } H_A : \mu \neq 1993$$

The term “independence” relates to the fact that for two groups of observations, you are testing whether or not the response variable is *independent* of the

explanatory variable that assigns the groups. In our case, we are testing whether the `decision` response variable is “independent” of the explanatory variable `gender` that assigns each résumé to either of the two groups.

3. generate replicates

After we `hypothesize()` the null hypothesis, we `generate()` replicates of “shuffled” datasets assuming the null hypothesis is true. We do this by repeating the shuffling exercise you performed in Section 3.3 several times. Instead of merely doing it 16 times as our groups of friends did, let’s use the computer to repeat this 1000 times by setting `reps = 1000` in the `generate()` function. However, unlike for confidence intervals where we generated replicates using `type = "bootstrap"` resampling with replacement, we’ll now perform shuffles/permutations by setting `type = "permute"`. Recall that shuffles/permutations are a kind of resampling, but unlike the bootstrap method, they involve resampling *without* replacement.

```
promotions_generate <- promotions %>%
  specify(formula = decision ~ gender, success = "promoted") %>%
  hypothesize(null = "independence") %>%
  generate(reps = 1000, type = "permute")
nrow(promotions_generate)
```

```
## [1] 48000
```

Observe that the resulting data frame has 48,000 rows. This is because we performed shuffles/permutations for each of the 48 rows 1000 times and $48,000 = 1000 \cdot 48$. If you explore the `promotions_generate` data frame with `View()`, you’ll notice that the variable `replicate` indicates which resample each row belongs to. So it has the value 1 48 times, the value 2 48 times, all the way through to the value 1000 48 times.

4. calculate summary statistics

Now that we have generated 1000 replicates of “shuffles” assuming the null hypothesis is true, let’s `calculate()` the appropriate summary statistic for each of our 1000 shuffles. From Section 3.4, point estimates related to hypothesis testing have a specific name: *test statistics*. Since the unknown population parameter of interest is the difference in population proportions $p_m - p_f$, the test statistic here is the difference in sample proportions $\hat{p}_m - \hat{p}_f$.

For each of our 1000 shuffles, we can calculate this test statistic by setting `stat = "diff in props"`. Furthermore, since we are interested in $\hat{p}_m - \hat{p}_f$ we set `order = c("male", "female")`. As we stated earlier, the order of the subtraction does not matter, so long as you stay consistent throughout your analysis and tailor your interpretations accordingly.

Let’s save the result in a data frame called `null_distribution`:

```

null_distribution <- promotions %>%
  specify(formula = decision ~ gender, success = "promoted") %>%
  hypothesize(null = "independence") %>%
  generate(reps = 1000, type = "permute") %>%
  calculate(stat = "diff in props", order = c("male", "female"))
null_distribution

```

```

## # A tibble: 1,000 x 2
##   replicate    stat
##   <int>    <dbl>
## 1         1 -0.0417
## 2         2 -0.125
## 3         3 -0.125
## 4         4 -0.0417
## 5         5 -0.0417
## 6         6 -0.125
## 7         7 -0.125
## 8         8 -0.125
## 9         9 -0.0417
## 10        10 -0.0417
## # ... with 990 more rows

```

Observe that we have 1000 values of `stat`, each representing one instance of $\hat{p}_m - \hat{p}_f$ in a hypothesized world of no gender discrimination. Observe as well that we chose the name of this data frame carefully: `null_distribution`. Recall once again from Section 3.4 that sampling distributions when the null hypothesis H_0 is assumed to be true have a special name: the *null distribution*.

What was the *observed* difference in promotion rates? In other words, what was the *observed test statistic* $\hat{p}_m - \hat{p}_f$? Recall from Section 3.3 that we computed this observed difference by hand to be $0.875 - 0.583 = 0.292 = 29.2\%$. We can also compute this value using the previous `infer` code but with the `hypothesize()` and `generate()` steps removed. Let's save this in `obs_diff_prop`:

```

obs_diff_prop <- promotions %>%
  specify(decision ~ gender, success = "promoted") %>%
  calculate(stat = "diff in props", order = c("male", "female"))
obs_diff_prop

```

```

## # A tibble: 1 x 1
##   stat
##   <dbl>
## 1 0.292

```

5. visualize the p-value

The final step is to measure how surprised we are by a promotion difference of 29.2% in a hypothesized universe of no gender discrimination. If the observed difference of 0.292 is highly unlikely, then we would be inclined to reject the validity of our hypothesized universe.

We start by visualizing the *null distribution* of our 1000 values of $\hat{p}_m - \hat{p}_f$ using `visualize()` in Figure 3.5. Recall that these are values of the difference in promotion rates assuming H_0 is true. This corresponds to being in our hypothesized universe of no gender discrimination.

```
visualize(null_distribution, bins = 10)
```




Figura 3.5: Null distribution.

Let's now add what happened in real life to Figure 3.5, the observed difference in promotion rates of $0.875 - 0.583 = 0.292 = 29.2\%$. However, instead of merely adding a vertical line using `geom_vline()`, let's use the `shade_p_value()` function with `obs_stat` set to the observed test statistic value we saved in `obs_diff_prop`.

Furthermore, we'll set the `direction = "right"` reflecting our alternative hypothesis $H_A : p_m - p_f > 0$. Recall our alternative hypothesis H_A is that $p_m - p_f > 0$, stating that there is a difference in promotion rates in favor of résumés with male names. "More extreme" here corresponds to differences that are "bigger" or "more positive" or "more to the right." Hence we set the `direction` argument of `shade_p_value()` to be "right".

On the other hand, had our alternative hypothesis H_A been the other possible one-sided alternative $p_m - p_f < 0$, suggesting discrimination in favor of résumés with female names, we would've set `direction = "left"`. Had our alternative hypothesis H_A been two-sided $p_m - p_f \neq 0$, suggesting discrimination in either direction, we would've set `direction = "both"`.

```
visualize(null_distribution, bins = 10) +  
  shade_p_value(obs_stat = obs_diff_prop, direction = "right")
```

In the resulting Figure 3.6, the solid dark line marks $0.292 = 29.2\%$. However, what does the shaded-region correspond to? This is the *p-value*. Recall the




Figure 3.6: Shaded histogram to show p -value.

definition of the p -value from Section 3.4:

A p -value is the probability of obtaining a test statistic just as or more extreme than the observed test statistic *assuming the null hypothesis H_0 is true*. So judging by the shaded region in Figure 3.6, it seems we would somewhat rarely observe differences in promotion rates of $0.292 = 29.2\%$ or more in a hypothesized universe of no gender discrimination. In other words, the p -value is somewhat small. Hence, we would be inclined to reject this hypothesized universe, or using statistical language we would “reject H_0 .”

What fraction of the null distribution is shaded? In other words, what is the exact value of the p -value? We can compute it using the `get_p_value()` function with the same arguments as the previous `shade_p_value()` code:

```

null_distribution %>%
  get_p_value(obs_stat = obs_diff_prop, direction = "right")

## # A tibble: 1 x 1
##   p_value
##   <dbl>
## 1    0.027

```

Keeping the definition of a p -value in mind, the probability of observing a

difference in promotion rates as large as $0.292 = 29.2\%$ due to sampling variation alone in the null distribution is $0.027 = 2.7\%$. Since this p -value is smaller than our pre-specified significance level $\alpha = 0.05$, we reject the null hypothesis $H_0 : p_m - p_f = 0$. In other words, this p -value is sufficiently small to reject our hypothesized universe of no gender discrimination. We instead have enough evidence to change our mind in favor of gender discrimination being a likely culprit here. Observe that whether we reject the null hypothesis H_0 or not depends in large part on our choice of significance level α . We'll discuss this more in Subsection 3.6.3.

3.5.2 Comparison with confidence intervals

One of the great things about the `infer` package is that we can jump seamlessly between conducting hypothesis tests and constructing confidence intervals with minimal changes! Recall the code from the previous section that creates the null distribution, which in turn is needed to compute the p -value:

```
null_distribution <- promotions %>%
  specify(formula = decision ~ gender, success = "promoted") %>%
  hypothesize(null = "independence") %>%
  generate(reps = 1000, type = "permute") %>%
  calculate(stat = "diff in props", order = c("male", "female"))
```

To create the corresponding bootstrap distribution needed to construct a 95% confidence interval for $p_m - p_f$, we only need to make two changes. First, we remove the `hypothesize()` step since we are no longer assuming a null hypothesis H_0 is true. We can do this by deleting or commenting out the `hypothesize()` line of code. Second, we switch the `type` of resampling in the `generate()` step to be `"bootstrap"` instead of `"permute"`.

```
bootstrap_distribution <- promotions %>%
  specify(formula = decision ~ gender, success = "promoted") %>%
  # Change 1 - Remove hypothesize():
  # hypothesize(null = "independence") %>%
  # Change 2 - Switch type from "permute" to "bootstrap":
  generate(reps = 1000, type = "bootstrap") %>%
  calculate(stat = "diff in props", order = c("male", "female"))
```

Using this `bootstrap_distribution`, let's first compute the percentile-based confidence intervals, as we did in Section ??:

```
percentile_ci <- bootstrap_distribution %>%
  get_confidence_interval(level = 0.95, type = "percentile")
percentile_ci
```

```
## # A tibble: 1 x 2
##   lower_ci upper_ci
##     <dbl>   <dbl>
```



```
## 1 0.0635 0.525
```

Using our shorthand interpretation for 95% confidence intervals from Subsection ??, we are 95% “confident” that the true difference in population proportions $p_m - p_f$ is between (0.063, 0.525). Let’s visualize `bootstrap_distribution` and this percentile-based 95% confidence interval for $p_m - p_f$ in Figure 3.7.

```
visualize(bootstrap_distribution) +  
  shade_confidence_interval(endpoints = percentile_ci)
```




Figure 3.7: Percentile-based 95% confidence interval.

Notice a key value that is not included in the 95% confidence interval for $p_m - p_f$: the value 0. In other words, a difference of 0 is not included in our net, suggesting that p_m and p_f are truly different! Furthermore, observe how the entirety of the 95% confidence interval for $p_m - p_f$ lies above 0, suggesting that this difference is in favor of men.

Since the bootstrap distribution appears to be roughly normally shaped, we can also use the standard error method as we did in Section ?. In this case, we must specify the `point_estimate` argument as the observed difference in promotion rates $0.292 = 29.2\%$ saved in `obs_diff_prop`. This value acts as the center of the confidence interval.

```
se_ci <- bootstrap_distribution %>%  
  get_confidence_interval(level = 0.95, type = "se",  
    point_estimate = obs_diff_prop)  
se_ci
```

```
## # A tibble: 1 x 2  
##   lower_ci upper_ci  
##   <dbl>    <dbl>  
## 1 0.0587 0.525
```

Let's visualize `bootstrap_distribution` again, but now the standard error based 95% confidence interval for $p_m - p_f$ in Figure 3.8. Again, notice how the value 0 is not included in our confidence interval, again suggesting that p_m and p_f are truly different!

```
visualize(bootstrap_distribution) +  
  shade_confidence_interval(endpoints = se_ci)
```




Figura 3.8: Standard error-based 95% confidence interval.

3.5.3 “There is only one test”

Let's recap the steps necessary to conduct a hypothesis test using the terminology, notation, and definitions related to sampling you saw in Section 3.4 and the `infer` workflow from Subsection 3.5.1:

1. `specify()` the variables of interest in your data frame.
2. `hypothesize()` the null hypothesis H_0 . In other words, set a “model for the universe” assuming H_0 is true.
3. `generate()` shuffles assuming H_0 is true. In other words, *simulate* data assuming H_0 is true.
4. `calculate()` the *test statistic* of interest, both for the observed data and your *simulated* data.
5. `visualize()` the resulting *null distribution* and compute the *p-value* by comparing the null distribution to the observed test statistic.

While this is a lot to digest, especially the first time you encounter hypothesis testing, the nice thing is that once you understand this general framework, then you can understand *any* hypothesis test. In a famous blog post, computer scientist Allen Downey called this the “There is only one test” framework, for which he created the flowchart displayed in Figure ??.

Notice its similarity with the “hypothesis testing with `infer`” diagram you saw in Figure ???. That’s because the `infer` package was explicitly designed to match the “There is only one test” framework. So if you can understand the framework, you can easily generalize these ideas for all hypothesis testing scenarios. Whether for population proportions p , population means μ , differences in population proportions $p_1 - p_2$, differences in population means $\mu_1 - \mu_2$, and as you’ll see in Chapter ?? on inference for regression, population regression slopes β_1 as well. In fact, it applies more generally even than just these examples to more complicated hypothesis tests and test statistics as well.

3.6 Interpreting hypothesis tests

Interpreting the results of hypothesis tests is one of the more challenging aspects of this method for statistical inference. In this section, we’ll focus on ways to help with deciphering the process and address some common misconceptions.

3.6.1 Two possible outcomes

In Section 3.4, we mentioned that given a pre-specified significance level α there are two possible outcomes of a hypothesis test:

- If the p -value is less than α , then we *reject* the null hypothesis H_0 in favor of H_A .
- If the p -value is greater than or equal to α , we *fail to reject* the null hypothesis H_0 .

Unfortunately, the latter result is often misinterpreted as “accepting the null hypothesis H_0 .” While at first glance it may seem that the statements “failing to reject H_0 ” and “accepting H_0 ” are equivalent, there actually is a subtle difference. Saying that we “accept the null hypothesis H_0 ” is equivalent to stating that “we think the null hypothesis H_0 is true.” However, saying that we “fail to reject the null hypothesis H_0 ” is saying something else: “While H_0 might still be false, we don’t have enough evidence to say so.” In other words, there is an absence of enough proof. However, the absence of proof is not proof of absence.

To further shed light on this distinction, let’s use the United States criminal justice system as an analogy. A criminal trial in the United States is a similar situation to hypothesis tests whereby a choice between two contradictory claims must be made about a defendant who is on trial:

1. The defendant is truly either “innocent” or “guilty.”
2. The defendant is presumed “innocent until proven guilty.”
3. The defendant is found guilty only if there is *strong evidence* that the defendant is guilty. The phrase “beyond a reasonable doubt” is often used as a guideline for determining a cutoff for when enough evidence exists to find the defendant guilty.

4. The defendant is found to be either “not guilty” or “guilty” in the ultimate verdict.

In other words, *not guilty* verdicts are not suggesting the defendant is *innocent*, but instead that “while the defendant may still actually be guilty, there wasn’t enough evidence to prove this fact.” Now let’s make the connection with hypothesis tests:

1. Either the null hypothesis H_0 or the alternative hypothesis H_A is true.
2. Hypothesis tests are conducted assuming the null hypothesis H_0 is true.
3. We reject the null hypothesis H_0 in favor of H_A only if the evidence found in the sample suggests that H_A is true. The significance level α is used as a guideline to set the threshold on just how strong of evidence we require.
4. We ultimately decide to either “fail to reject H_0 ” or “reject H_0 .”

So while gut instinct may suggest “failing to reject H_0 ” and “accepting H_0 ” are equivalent statements, they are not. “Accepting H_0 ” is equivalent to finding a defendant innocent. However, courts do not find defendants “innocent,” but rather they find them “not guilty.” Putting things differently, defense attorneys do not need to prove that their clients are innocent, rather they only need to prove that clients are not “guilty beyond a reasonable doubt”.

So going back to our résumés activity in Section 3.5, recall that our hypothesis test was $H_0 : p_m - p_f = 0$ versus $H_A : p_m - p_f > 0$ and that we used a pre-specified significance level of $\alpha = 0.05$. We found a p -value of 0.027. Since the p -value was smaller than $\alpha = 0.05$, we rejected H_0 . In other words, we found needed levels of evidence in this particular sample to say that H_0 is false at the $\alpha = 0.05$ significance level. We also state this conclusion using non-statistical language: we found enough evidence in this data to suggest that there was gender discrimination at play.

3.6.2 Types of errors

Unfortunately, there is some chance a jury or a judge can make an incorrect decision in a criminal trial by reaching the wrong verdict. For example, finding a truly innocent defendant “guilty”. Or on the other hand, finding a truly guilty defendant “not guilty.” This can often stem from the fact that prosecutors don’t have access to all the relevant evidence, but instead are limited to whatever evidence the police can find.

The same holds for hypothesis tests. We can make incorrect decisions about a population parameter because we only have a sample of data from the population and thus sampling variation can lead us to incorrect conclusions.

There are two possible erroneous conclusions in a criminal trial: either (1) a truly innocent person is found guilty or (2) a truly guilty person is found not guilty. Similarly, there are two possible errors in a hypothesis test: either (1) rejecting H_0 when in fact H_0 is true, called a **Type I error** or (2) failing to reject H_0 when in fact H_0 is false, called a **Type II error**. Another term used

for “Type I error” is “false positive,” while another term for “Type II error” is “false negative.”

This risk of error is the price researchers pay for basing inference on a sample instead of performing a census on the entire population. But as we’ve seen in our numerous examples and activities so far, censuses are often very expensive and other times impossible, and thus researchers have no choice but to use a sample. Thus in any hypothesis test based on a sample, we have no choice but to tolerate some chance that a Type I error will be made and some chance that a Type II error will occur.

To help understand the concepts of Type I error and Type II errors, we apply these terms to our criminal justice analogy in Figure ??.

Thus a Type I error corresponds to incorrectly putting a truly innocent person in jail, whereas a Type II error corresponds to letting a truly guilty person go free. Let’s show the corresponding table in Figure ?? for hypothesis tests.

3.6.3 How do we choose alpha?

If we are using a sample to make inferences about a population, we run the risk of making errors. For confidence intervals, a corresponding “error” would be constructing a confidence interval that does not contain the true value of the population parameter. For hypothesis tests, this would be making either a Type I or Type II error. Obviously, we want to minimize the probability of either error; we want a small probability of making an incorrect conclusion:

- The probability of a Type I Error occurring is denoted by α . The value of α is called the *significance level* of the hypothesis test, which we defined in Section 3.4.
- The probability of a Type II Error is denoted by β . The value of $1 - \beta$ is known as the *power* of the hypothesis test.

In other words, α corresponds to the probability of incorrectly rejecting H_0 when in fact H_0 is true. On the other hand, β corresponds to the probability of incorrectly failing to reject H_0 when in fact H_0 is false.

Ideally, we want $\alpha = 0$ and $\beta = 0$, meaning that the chance of making either error is 0. However, this can never be the case in any situation where we are sampling for inference. There will always be the possibility of making either error when we use sample data. Furthermore, these two error probabilities are inversely related. As the probability of a Type I error goes down, the probability of a Type II error goes up.

What is typically done in practice is to fix the probability of a Type I error by pre-specifying a significance level α and then try to minimize β . In other words, we will tolerate a certain fraction of incorrect rejections of the null hypothesis H_0 , and then try to minimize the fraction of incorrect non-rejections of H_0 .

So for example if we used $\alpha = 0.01$, we would be using a hypothesis testing procedure that in the long run would incorrectly reject the null hypothesis H_0 one percent of the time. This is analogous to setting the confidence level of a confidence interval.

So what value should you use for α ? Different fields have different conventions, but some commonly used values include 0.10, 0.05, 0.01, and 0.001. However, it is important to keep in mind that if you use a relatively small value of α , then all things being equal, p -values will have a harder time being less than α . Thus we would reject the null hypothesis less often. In other words, we would reject the null hypothesis H_0 only if we have *very strong* evidence to do so. This is known as a “conservative” test.

On the other hand, if we used a relatively large value of α , then all things being equal, p -values will have an easier time being less than α . Thus we would reject the null hypothesis more often. In other words, we would reject the null hypothesis H_0 even if we only have *mild* evidence to do so. This is known as a “liberal” test.

3.7 Conclusions

3.7.1 When inference is not needed

We’ve now walked through several different examples of how to use the `infer` package to perform statistical inference: constructing confidence intervals and conducting hypothesis tests. For each of these examples, we made it a point to always perform an exploratory data analysis (EDA) first; specifically, by looking at the raw data values, by using data visualization with `ggplot2`, and by data wrangling with `dplyr` beforehand. We *highly* encourage you to always do the same. As a beginner to statistics, EDA helps you develop intuition as to what statistical methods like confidence intervals and hypothesis tests can tell us. Even as a seasoned practitioner of statistics, EDA helps guide your statistical investigations. In particular, is statistical inference even needed?

Let’s consider an example. Say we’re interested in the following question: Of *all* flights leaving a New York City airport, are Hawaiian Airlines flights in the air for longer than Alaska Airlines flights? Furthermore, let’s assume that 2013 flights are a representative sample of all such flights. Then we can use the `flights` data frame in the `nycflights13` package we introduced in Section ?? to answer our question. Let’s filter this data frame to only include Hawaiian and Alaska Airlines using their `carrier` codes HA and AS:

```
flights_sample <- flights %>%
  filter(carrier %in% c("HA", "AS"))
```

There are two possible statistical inference methods we could use to answer such questions. First, we could construct a 95% confidence interval for the difference in population means $\mu_{HA} - \mu_{AS}$, where μ_{HA} is the mean air time of all Hawaiian

Airlines flights and μ_{AS} is the mean air time of all Alaska Airlines flights. We could then check if the entirety of the interval is greater than 0, suggesting that $\mu_{HA} - \mu_{AS} > 0$, or, in other words suggesting that $\mu_{HA} > \mu_{AS}$. Second, we could perform a hypothesis test of the null hypothesis $H_0 : \mu_{HA} - \mu_{AS} = 0$ versus the alternative hypothesis $H_A : \mu_{HA} - \mu_{AS} > 0$.

However, let's first construct an exploratory visualization as we suggested earlier. Since `air_time` is numerical and `carrier` is categorical, a boxplot can display the relationship between these two variables, which we display in Figure 3.9.

```
ggplot(data = flights_sample, mapping = aes(x = carrier, y = air_time)) +
  geom_boxplot() +
  labs(x = "Carrier", y = "Air Time")
```

```
## Warning: Removed 5 rows containing non-finite values (stat_boxplot).
```




Figura 3.9: Air time for Hawaiian and Alaska Airlines flights departing NYC in 2013.

This is what we like to call “no PhD in Statistics needed” moments. You don’t have to be an expert in statistics to know that Alaska Airlines and Hawaiian Airlines have *significantly* different air times. The two boxplots don’t even overlap! Constructing a confidence interval or conducting a hypothesis test would frankly not provide much more insight than Figure 3.9.

Let’s investigate why we observe such a clear cut difference between these two airlines using data wrangling. Let’s first group by the rows of `flights_sample` not only by `carrier` but also by destination `dest`. Subsequently, we’ll compute two summary statistics: the number of observations using `n()` and the mean airtime:

```
flights_sample %>%
  group_by(carrier, dest) %>%
  summarize(n = n(), mean_time = mean(air_time, na.rm = TRUE))
```

```
## `summarise()` regrouping output by 'carrier' (override with `.groups` argument)
## # A tibble: 2 x 4
## # Groups:   carrier [2]
##   carrier dest      n mean_time
##   <chr>   <chr> <int>      <dbl>
## 1 AS     SEA     714      326.
## 2 HA     HNL     342      623.
```

It turns out that from New York City in 2013, Alaska only flew to SEA (Seattle) from New York City (NYC) while Hawaiian only flew to HNL (Honolulu) from NYC. Given the clear difference in distance from New York City to Seattle versus New York City to Honolulu, it is not surprising that we observe such different (*statistically significantly different*, in fact) air times in flights.

This is a clear example of not needing to do anything more than a simple exploratory data analysis using data visualization and descriptive statistics to get an appropriate conclusion. This is why we highly recommend you perform an EDA of any sample data before running statistical inference methods like confidence intervals and hypothesis tests.

3.7.2 Problems with p-values

On top of the many common misunderstandings about hypothesis testing and p -values we listed in Section 3.6, another unfortunate consequence of the expanded use of p -values and hypothesis testing is a phenomenon known as “p-hacking.” p-hacking is the act of “cherry-picking” only results that are “statistically significant” while dismissing those that aren’t, even if at the expense of the scientific ideas. There are lots of articles written recently about misunderstandings and the problems with p -values. We encourage you to check some of them out:

1. Misunderstandings of p -values
2. What a nerdy debate about p -values shows about science - and how to fix it
3. Statisticians issue warning over misuse of P values
4. You Can’t Trust What You Read About Nutrition
5. A Litany of Problems with p -values

Such issues were getting so problematic that the American Statistical Association (ASA) put out a statement in 2016 titled, “The ASA Statement on Statistical Significance and P -Values,” with six principles underlying the proper use and interpretation of p -values. The ASA released this guidance on p -values to improve the conduct and interpretation of quantitative science and to inform the growing emphasis on reproducibility of science research.

We as authors much prefer the use of confidence intervals for statistical inference, since in our opinion they are much less prone to large misinterpretation. However, many fields still exclusively use p -values for statistical inference and

this is one reason for including them in this text. We encourage you to learn more about “p-hacking” as well and its implication for science.

Capítulo 4

El muestreo estadístico

Some *significant* applications are demonstrated in this chapter.

4.1 Example one

4.2 Example two

Capítulo 5

Regresiones

We have finished a nice book.

Capítulo 6

Estadística multivariante

We have finished a nice book.

Bibliografía

- Knuth, D. E. (1984). Literate Programming. *The Computer Journal*, 27(2):97–111.
- Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., Golemund, G., Hayes, A., Henry, L., Hester, J., Kuhn, M., Pedersen, T. L., Miller, E., Bache, S. M., Müller, K., Ooms, J., Robinson, D., Seidel, D. P., Spinu, V., Takahashi, K., Vaughan, D., Wilke, C., Woo, K., and Yutani, H. (2019). Welcome to the tidyverse. *Journal of Open Source Software*, 4(43):1686.
- Wickham, H. and Golemund, G. (2017). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O’Reilly Media, Inc., 1st edition.
- Xie, Y. (2015). *Dynamic Documents with R and knitr*. Chapman and Hall/CRC, Boca Raton, Florida, 2nd edition. ISBN 978-1498716963.